



Всего песен: 26 178

**Количество уникальных
исполнителей:** 6 207


Всего нот: 1 338 346

Всего аккордов: 449 072

“Hey Jude” by The Beatles



Full song



HookTheory.com



Каждый клип — JSON-объект типа:

- meta: split, key, tempo, meter
- [melody]: beat, duration, scale, degree, octave, rest flag
- [chords]: beat, duration, root, type, inversion, applied, adds, omits, alterations, suspensions, borrowed, rest flag

Cmaj7add9

Asus4

D7/V

root type adds suspensions
applied



GNN Critic

Графовое представление данных





Схема иерархии и типов связей



Иерархия в формате нотной записи



GNN Critic

Пример искажений треков



Нотная запись до и после искажений



GNN Critic

Схема применения графового критика




Схема применения графового критика



GNN Critic

Схема обучения графового учителя

$\mathcal{G}$ – исходный граф

$\tilde{\mathcal{G}}$ – искаженный граф

Модель обучается
выполнять условие:

$$s_{\theta}(\mathcal{G}) > s_{\theta}(\tilde{\mathcal{G}})$$





Схема обучения графового учителя



GNN Critic

Схема обучения графового ученика



Общая схема обучения графового ученика



Ноты на

входе:

C - E - G - B

Возможная интерпретация	Функция	Лад / тональный контекст
Cmaj7	I — тоника	C Ionian
Em(b13)	i — модальная тоника	E Phrygian
G6sus4 (или G(add4,6))	I с суспензией / тоническое зависание	G Ionian
Cmaj7	III — медиантовая окраска	A melodic minor
Bø(addb9) (условная неполная трактовка)	iø — локрийская тоника	B Locrian
Cmaj7	V — доминантовая ступень без классического доминантового напряжения	F Lydian



Аккордовый оценщик выбирает кандидата с наибольшим количеством очков соответствия, которые считаются как:

$$q(c, P_w) = q_+(c, P_w) - q_-(c, P_w),$$

- P_w — наблюдаемые ноты;
- c — аккордовый кандидат;
- q_+ — **положительный вклад** объяснённых признаков;
- q_- — **штрафы за несоответствия**.



Сравнение случайных и теоретически обоснованных искажений

<i>Corruption family</i>	<i>Pooling</i>	<i>Best rank acc</i> ↑
<i>Theory-aware</i>	<i>mean_max</i>	1.0000
<i>Graph</i>	<i>mean_max</i>	0.8750



Проверка обобщения teacher-модели на OOD-corruptions

<i>Group</i>		<i>Mean gap</i>	<i>Global RankAcc</i>	<i>Interpretation</i>
<i>Harmful corruptions</i>	OOD	0.6649	0.5504	Новые вредные искажения в среднем понижают score
<i>Benign transformations</i>		0.0110	0.5012	Безвредные преобразования почти не создают систематический штраф



Таблица: *Staged training*

<i>Training mode</i>	<i>Best IntraAcc</i> ↑	<i>Best InterAcc</i> ↑	<i>BinaryAcc</i> ↑
<i>MLM → corruption</i>	0.9118	0.8994	0.7486
<i>Corruption from scratch</i>	0.9007	0.8962	0.7489

- *BinaryAcc* — точность бинарного различения исходных и искажённых графов.
- *IntraAcc* — точность упорядоченных пар *clean/corrupted* в рамках одного трека.
- *InterAcc* — точность упорядоченных пар *clean/corrupted* с разными треками.



Таблица: *Feature ablation: dynamic weighting, HGT и learned logit fusion*

Variant	Backbone	Dynamic weights	Logit fusion	Best IntraAcc $\uparrow$	Best InterAcc $\uparrow$	BinaryAcc $\uparrow$
Baseline	SAGE	no	no	0.8547	0.8472	0.7668
HGT	HGT	no	no	0.8410	0.8409	0.7537
Dynamic weights	SAGE	yes	no	0.8530	0.8494	0.7731
Learned logit fusion	SAGE	no	yes	0.8408	0.8523	0.7761

- *BinaryAcc* — точность бинарного различения исходных и искажённых графов.
- *IntraAcc* — точность упорядоченных пар *clean/corrupted* в рамках одного трека.
- *InterAcc* — точность упорядоченных пар *clean/corrupted* с разными треками.



Таблица: Финальная *teacher*-конфигурация

<i>Backbone</i>	<i>Dynamic weights</i>	<i>Logit fusion</i>	<i>Hidden / layers</i>	<i>Pooling</i>	<i>Local context</i>	<i>MLM / corr epochs</i>	<i>Best IntraAcc</i> ↑	<i>Best InterAcc</i> ↑	<i>BinaryAcc</i> ↑
SAGE	yes	yes	256 / 4	<i>mean_max</i>	<i>attention</i>	30 / 39	0.9275	0.9250	0.8456

- *BinaryAcc* — точность бинарного различения исходных и искажённых графов.
- *IntraAcc* — точность упорядоченных пар *clean/corrupted* в рамках одного трека.
- *InterAcc* — точность упорядоченных пар *clean/corrupted* с разными треками.



Таблица: Сравнение ручного и обучаемого *scoring* для восстановления аккордов из *MIDI*

Scoring	Top-1 exact ↑	Top-5 contains GT ↑	Root acc ↑	Type acc ↑	Root+Type acc ↑	Mode acc ↑	Inversion acc ↑
Learned weights	0.9216	0.9907	0.9753	0.9864	0.9690	0.9324	0.9811
Manual	0.7641	0.9184	0.9249	0.8368	0.8147	0.9061	0.9213



Таблица: Качество восстановления аккордов по типам

Type	Manual weights $\uparrow$	Learned weights $\uparrow$
triad / 5	0.915	0.938
seventh / 7	0.227	0.867
ninth / 9	0.000	0.850
eleventh / 11	0.000	0.886
thirteenth / 13	0.000	0.089



$$\mathcal{L} = \lambda_s \mathcal{L}_{score} + \lambda_r \mathcal{L}_{rank} + \lambda_m \mathcal{L}_{margin} + \lambda_g \mathcal{L}_{graph} + \lambda_t \mathcal{L}_{type} + \lambda_l \mathcal{L}_{local}.$$

$$\mathcal{L}_{graph} = \left\| P_g z_G^S - z_G^T \right\|_2^2$$

$$\mathcal{L}_{type} = \sum_{\tau} \left\| P_{\tau} z_{\tau}^S - z_{\tau}^T \right\|_2^2$$

$$\mathcal{L}_{local} = \left\| P_l u^S - u^T \right\|_2^2$$

z_G^S и z_G^T — графовые *embeddings* *student*- и *teacher*-моделей.

z_{τ}^S и z_{τ}^T — *pooled*-представления по типам вершин.

u^S и u^T — локальные *summary*-признаки.

Матрицы P_g , P_{τ} , P_l являются *projection adapters*, позволяющими сопоставить пространства *student* и *teacher*.



Таблица: Влияние дистилляции промежуточных представлений *teacher*-модели

Variant	Batch rank acc ↑	Spearman ↑	Pearson ↑	MAE ↓	Score distill loss ↓
Intermediate	0.6787	0.4173	0.3588	2.3121	3.7560
No intermediate	0.6111	0.2712	0.1728	2.5432	4.2046

Batch rank acc — доля корректных сравнений между всеми положительными и отрицательными примерами внутри батча.

Spearman — ранговая корреляция между оценками *student* и *teacher*.

Pearson — линейная корреляция между этими оценками.



Таблица: Финальное сравнение *observer*-конфигураций

<i>Observer variant</i>	<i>Intermediate losses</i>	<i>Pair rank acc</i> ↑	<i>Batch rank acc</i> ↑	<i>Spearman</i> ↑	<i>Pearson</i> ↑	<i>MAE</i> ↓
<i>Intermediate</i>	<i>yes</i>	0.8692	0.8464	0.6926	0.6873	2.0698
<i>No intermediate</i>	<i>no</i>	0.8509	0.8387	0.7135	0.6832	1.4717




Appendix

Распределения тональностей и ладов



Распределение тональностей




Распределение ладов



Appendix

Распределения ступеней и типов аккордов



Распределение ступеней аккордов



Распределение типов аккордов



Appendix

Обучение графового учителя

Признаки каждой вершины проецируются в общее скрытое пространство:

$$h_v^{(0)} = \phi_{\tau_v}(x_v),$$

где ϕ_{τ_v} — *encoder* для типа вершины τ_v , реализованный как *MLP*.

Для каждого типа ребра r сообщения вычисляются отдельно:

$$m_{u \rightarrow v}^{(l,r)} = W_r^{(l)} h_u^{(l)}.$$

Сообщения от соседей агрегируются:

$$m_v^{(l)} = \sum_{r \in R} \text{AGG}_{u \in N_r(v)} m_{u \rightarrow v}^{(l,r)}.$$

Состояние вершины обновляется с *residual*-связью, нормализацией и нелинейностью:

$$h_v^{(l+1)} = \text{ReLU}\left(\text{LN}\left(h_v^{(l)} + m_v^{(l)}\right)\right).$$

После нескольких *GNN*-слоёв модель получает контекстуализированные представления узлов. Затем выполняется *pooling* по типам вершин:

$$g_t = \frac{1}{|V_t|} \sum_{v \in V_t} h_v^{(l)},$$

где V_t — множество вершин типа t .

После объединения векторов разных типов получается общий *embedding* графа:

$$g = \psi(g_1 \| g_2 \| \dots \| g_T),$$

где $\|$ — конкатенация, а ψ — линейная проекция или *MLP*. Итоговая оценка графа:

$$s_\theta(\mathcal{G}) = f_{\text{score}}(g).$$

Для обучения используется *contrastive ranking loss*:

$$\mathcal{L}_{\text{rank}} = \text{softplus}\left(-\left(s_\theta(\mathcal{G}) - s_\theta(\tilde{\mathcal{G}}) - m\right)\right),$$

где m — *margin*. Функция штрафует модель, если *score* искажённого графа слишком близок к *score* исходного или превосходит его.

Дополнительно может использоваться бинарная классификационная компонента:

$$\mathcal{L}_{\text{bin}} = \frac{1}{2} \left(\text{BCE}(s_\theta(\mathcal{G}), 1) + \text{BCE}(s_\theta(\tilde{\mathcal{G}}), 0) \right).$$

Общая функция потерь учителя:

$$\mathcal{L}_{\text{teacher}} = \lambda_{\text{rank}} \mathcal{L}_{\text{rank}} + \lambda_{\text{bin}} \mathcal{L}_{\text{bin}} + \lambda_{\text{local}} \mathcal{L}_{\text{local}} + \lambda_{\text{rec}} \mathcal{L}_{\text{rec}}.$$



Appendix

Обучение графового ученика

После построения *MIDI*-графа ученик использует компактную гетерогенную *GNN*. Для каждой вершины строится начальное представление:

$$z_v^{(0)} = \phi_{\tau_v}(x_v),$$

после чего несколько графовых слоёв обновляют его через сообщения от соседей:

$$z_v^{(l+1)} = \sigma \left(\text{LN} \left(z_v^{(l)} + \sum_r \text{AGG}_{u \in N_r(v)} W_r^{(l)} z_u^{(l)} \right) \right).$$

Далее применяется *pooling* по вершинам и строится *embedding MIDI*-графа:

$$z_G = \text{Pool} \left(\{z_v^{(L)}\}_{v \in V_M} \right).$$

Итоговая оценка ученика равна:

$$s_\varphi(\mathcal{G}_M) = f_{\text{student}}(z_G).$$

Ученик обучается не на ручных метках, а на оценках учителя. Если учитель присваивает музыкальному фрагменту *score* $s_\theta(\mathcal{G})$, то ученик минимизирует ошибку дистилляции:

$$\mathcal{L}_{\text{distill}} = |s_\varphi(\mathcal{G}_M) - s_\theta(\mathcal{G})|,$$

или её сглаженный вариант:

$$\mathcal{L}_{\text{distill}} = \text{SmoothL1}(s_\varphi(\mathcal{G}_M), s_\theta(\mathcal{G})).$$

Для пар *clean/corrupted* дополнительно используется *ranking loss*:

$$\mathcal{L}_{\text{student-rank}} = \text{softplus} \left(- \left(s_\varphi(\mathcal{G}_M) - s_\varphi(\tilde{\mathcal{G}}_M) \right) \right).$$



Appendix

Положительная часть аккордового score

Компоненты положительной части аккордового score

Компонента	Интерпретация
mode_match(c)	Совпадение лада
bass_match(c)	Совпадение басовой ноты
$ P_w \cap B(c) $	Количество совпадающих нот
explained_extras(c, P_w)	Надстройки



Компоненты штрафной части аккордового score

Компонента	Интерпретация
Unexplained(c, P_w)	Ноты которые не объясняются кандидатом
MissingCore(c, P_w)	Ноты кандидата которых нет в MIDI
borrowed_mode_penalty(c)	Штраф за заимствованный лад
mode_distance(c)	Штраф за расстояние до заимствованного лада
body_size_penalty(c)	Штраф за размер аккорда
complexity_penalty(c)	Штрафы за добавленные ступени, задержания, альтерации и пропущенные обязательные тона.



Appendix

Пример применения аккордового оценщика

Пусть в момент времени t наблюдаются *MIDI*-ноты $C - E - G - B\flat$, тогда $P_t = \{C, E, G, B\flat\}$.

Кандидат	Тело аккорда	Совпадения и штрафы	Итог
$C7$	$B(C7) = \{C, E, G, B\flat\}$	$P_t \cap B(C7) = \{C, E, G, B\flat\};$ $\text{MissingCore} = \emptyset;$ $\text{Unexplained} = \emptyset$	Высокий score: полный доминантсепт-аккорд.
C major	$B(C) = \{C, E, G\}$	Трезвучие объясняется, но $B\flat$ остаётся необъяснённым: $\text{Unexplained} = \{B\flat\}$	Score ниже, если $B\flat$ не считается допустимой добавленной или альтерированной ступенью.
$Am7\flat5/C$	$B(Am7\flat5) = \{A, C, E\flat, G\}$	Есть C и G , но отсутствуют A и $E\flat$; вместо $E\flat$ наблюдается E : $\text{MissingCore} = \{A, E\flat\}$	Совпадение баса C не компенсирует штрафы: score ниже, чем у $C7$.