



Факультет компьютерных наук
НИУ ВШЭ

2026

Предлагаемый подход к последующему GRPO-дообучению text-to-MIDI

Материал по разделу “Предлагаемый подход”

Автор курсовой работы



Почему нужно последующее дообучение

- Базовая text-to-MIDI модель учится предсказывать следующий токен, но это не гарантирует качество всего музыкального фрагмента.
- Для итогового MIDI важны глобальные свойства: тональная согласованность, ритмическая устойчивость, фактура и соответствие текстовому описанию.
- Один запрос допускает несколько корректных музыкальных реализаций, поэтому обучение по одному эталону ограничено.
- Нужна схема, которая сравнивает несколько сгенерированных кандидатов и усиливает более удачные.



Общая идея подхода

1. Берём уже обученный генератор text-to-MIDI.
2. Для одного текстового запроса генерируем группу MIDI-кандидатов.
3. После декодирования оцениваем каждый кандидат правилами, критиком или их комбинацией.
4. Считаем относительное преимущество кандидатов внутри группы.
5. Обновляем модель в сторону более предпочтительных ответов с помощью GRPO.


Ключевая особенность

Награда вычисляется не на уровне отдельного токена, а по завершённой MIDI-последовательности.



Базовая модель Text2midi

- Исходный генератор рассматривается как условная политика $\pi_{\theta}(y | x)$.
- Вход: текстовый запрос с описанием жанра, настроения, темпа, размера и инструментов.
- Выход: авторегрессионно сгенерированная последовательность музыкальных токенов, которая затем декодируется в MIDI.
- Базовая модель уже умеет порождать валидные MIDI, но может создавать лишние дорожки, переуплотнённую фактуру и слабое соответствие запросу.





GRPO как схема дообучения

Для запроса q генерируется группа ответов

$$\{o_i\}_{i=1}^G \sim \pi_{\theta_{\text{old}}}(O \mid q), \quad r_i = R(q, o_i).$$

Относительное преимущество вычисляется внутри группы:

$$\hat{A}_i = \frac{r_i - \bar{r}}{s_r + \varepsilon_A}, \quad \bar{r} = \frac{1}{G} \sum_{j=1}^G r_j.$$

Оптимизируется clipped-цель с KL-регуляризацией к опорной модели:

$$\mathcal{L}_{\text{GRPO}} \propto \sum_{i,t} m_{i,t} \left(-\min(\rho_{i,t}(\theta) \hat{A}_i, \text{clip}(\rho_{i,t}(\theta), 1 - \epsilon, 1 + \epsilon) \hat{A}_i) + \beta D_{i,t} \right).$$

- Если кандидат лучше среднего по группе, вероятность его токенов увеличивается.
- KL-регуляризация не даёт модели слишком далеко уйти от исходного генератора.



Один шаг обучения

Этап	Операция	Назначение
1	Выбор запроса	Задаётся текстовое условие для группы кандидатов.
2	Генерация кандидатов	Модель порождает несколько MIDI-вариантов для одного запроса.
3	Декодирование	Токены преобразуются в музыкальное представление и MIDI-файл.
4	Вычисление награды	Кандидаты оцениваются правилами, критиком или смешанной схемой.
5	Нормировка в группе	Награды переводятся в относительные преимущества.
6	Обновление GRPO	Обновляются обучаемые параметры с clip-ограничением и KL-регуляризацией.

Дополнительно сохраняются артефакты шага: тексты запросов, MIDI-файлы, компоненты награды, статистика валидности и чекпойнты модели.



Что именно обучается

Основной режим

LoRA-адаптация в FFN-блоках декодера:

- слои `linear1` и `linear2`;
- меняется распределение музыкальных токенов;
- большая часть исходной модели остаётся замороженной.

Ожидаемый эффект

Сместить распределение генераций в сторону более музыкально согласованных и лучше соответствующих текстовому запросу MIDI-кандидатов.

Альтернатива

Прямое частичное дообучение
выбранных параметров:

- сильнее меняет поведение модели;
- требует более осторожного выбора `learning rate`;
- сильнее зависит от контроля KL.



- Предлагаемый подход не переобучает модель с нуля, а надстраивает поверх готового text-to-MIDI генератора этап согласования.
- Качество задаётся внешней наградой по завершённому MIDI-фрагменту, а не только вероятностями токенов.
- GRPO позволяет использовать относительное сравнение нескольких кандидатов без отдельной модели ценности.
- Практический акцент сделан на устойчивом дообучении с ограниченным числом обучаемых параметров.