

ПРАВИТЕЛЬСТВО РОССИЙСКОЙ ФЕДЕРАЦИИ  
ФГАОУ ВО НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ  
«ВЫСШАЯ ШКОЛА ЭКОНОМИКИ»

Факультет компьютерных наук  
Образовательная программа «Прикладная математика и информатика»

УДК XXXXX

Отчет об исследовательском проекте на тему:  
Сжатие словарей для нейросетевого анализа исходных кодов программ  
(промежуточный, этап 1)

**Выполнил студент:**

группы #БПМИ171, 3 курса

Гусев Андрей Алексеевич

**Принял руководитель проекта:**

Чиркова Надежда Александровна

Научный сотрудник

Факультет компьютерных наук НИУ ВШЭ

Москва 2024

# Содержание

|                                                                    |           |
|--------------------------------------------------------------------|-----------|
| <b>Аннотация</b>                                                   | <b>4</b>  |
| <b>1 Постановка задачи text-to-midi</b>                            | <b>5</b>  |
| <b>2 Обзор существующих решений</b>                                | <b>5</b>  |
| <b>3 Мотивация последующего дообучения</b>                         | <b>6</b>  |
| <b>4 Предлагаемый подход</b>                                       | <b>7</b>  |
| 4.1 Постановка задачи и общая идея . . . . .                       | 7         |
| 4.2 Базовая модель Text2midi . . . . .                             | 7         |
| 4.3 GRPO как схема последующего дообучения . . . . .               | 8         |
| 4.4 Один шаг обучения в реализованной процедуре . . . . .          | 10        |
| 4.5 Настройка обучаемых параметров модели . . . . .                | 11        |
| 4.6 Формирование текстовых запросов . . . . .                      | 11        |
| 4.7 Стратегия выбора запросов для обучения . . . . .               | 12        |
| 4.8 Проектирование функции награды . . . . .                       | 12        |
| 4.9 Структура используемых компонент награды . . . . .             | 13        |
| 4.9.1 Общие обозначения и нормировка . . . . .                     | 13        |
| 4.9.2 Тональная согласованность . . . . .                          | 13        |
| 4.9.3 Метрическая организация . . . . .                            | 14        |
| 4.9.4 Длительность и плотность нот . . . . .                       | 14        |
| 4.9.5 Дорожки и ударные инструменты . . . . .                      | 14        |
| 4.9.6 Валидность и внешний критик . . . . .                        | 15        |
| 4.9.7 Итоговая функция награды . . . . .                           | 15        |
| 4.10 Конфликты между компонентами награды . . . . .                | 15        |
| 4.11 Ожидаемые преимущества и исследовательские гипотезы . . . . . | 15        |
| <b>5 Экспериментальная часть</b>                                   | <b>16</b> |
| 5.1 Цели экспериментального исследования . . . . .                 | 16        |
| 5.2 Инфраструктура и программная реализация . . . . .              | 17        |
| 5.3 Семейства исследуемых конфигураций . . . . .                   | 18        |
| 5.4 Конфигурации текстовых запросов и режимов генерации . . . . .  | 19        |
| 5.5 Сравнимые стратегии адаптации параметров . . . . .             | 21        |

|          |                                                      |           |
|----------|------------------------------------------------------|-----------|
| 5.6      | Внутренние метрики и диагностика обучения . . . . .  | 21        |
| 5.7      | Построение внешней оценки качества . . . . .         | 22        |
| 5.7.1    | А/В-сравнение базовой и дообученной модели . . . . . | 23        |
| 5.7.2    | Оценка с помощью внешней языковой модели . . . . .   | 23        |
| <b>6</b> | <b>Результаты экспериментов</b>                      | <b>23</b> |
| 6.1      | Динамика обучения . . . . .                          | 23        |
| 6.2      | А/В-сравнение . . . . .                              | 28        |
| 6.3      | Оценка внешней языковой моделью . . . . .            | 28        |
| <b>7</b> | <b>Анализ ошибок и ограничений</b>                   | <b>29</b> |
| <b>8</b> | <b>Заключение</b>                                    | <b>31</b> |
|          | <b>Список литературы</b>                             | <b>33</b> |

## Аннотация

В работе исследуется последующее дообучение модели text-to-MIDI с использованием групповой оптимизации по относительным оценкам сгенерированных MIDI-фрагментов. Обучающий сигнал строится из критериев, которые трудно задать при обычном контролируемом обучении: тональной согласованности, ритмической устойчивости, плотности нот, доли ударных событий и оценки внешнего музыкального критика.

## Ключевые слова

Text-to-MIDI, символьная генерация музыки, GRPO, обучение с подкреплением, MIDI, функция награды, LoRA

# 1 Постановка задачи text-to-midi

Задача text-to-midi состоит в генерации MIDI-последовательности по текстовому описанию музыкального фрагмента. Модель получает запрос на естественном языке и должна построить символьное музыкальное представление: ноты, длительности, ритмическую организацию, темп, инструменты и другие свойства композиции [20, 9, 10, 2]. В общем виде модель должна аппроксимировать условное распределение  $p(y | x)$ , где  $x$  — текстовое условие, а  $y$  — MIDI-фрагмент.

Эта постановка отличается от безусловной генерации музыки: недостаточно получить правдоподобную музыкальную последовательность, её нужно ещё согласовать с запросом. Она также отличается от задач, где условием служит уже заданный музыкальный материал, например мелодия или аккордовая последовательность [8, 9]. В text-to-midi условие принадлежит языковой модальности, поэтому модель должна связать слова о жанре, настроении, темпе, размере, инструментах и фактуре с конкретными музыкальными событиями.

Для задачи принципиальна неоднозначность. Один текстовый запрос может иметь несколько корректных музыкальных реализаций, поэтому качество нельзя свести к точному совпадению с единственным эталоном. Именно поэтому далее, в разделе 4, модель дообучается не по готовой целевой MIDI-последовательности, а по относительному качеству нескольких сгенерированных кандидатов.

## 2 Обзор существующих решений

Развитие text-to-midi связано с более общим переходом от безусловной символьной генерации к управляемой генерации музыки. Сначала управление задавалось структурированными признаками: эмоцией, стилем, темпом, аккордовой основой или другими атрибутами [16, 8]. Такие признаки проще извлекать из данных, но они хуже соответствуют пользовательскому сценарию, где удобнее задавать музыку свободным текстом.

Ранние работы уже связывали текст и символьную музыку, но чаще в более узкой постановке. *TeleMelody* использует текст как источник шаблонов для генерации мелодии, а *BUTTER* рассматривает совместное представление музыкальных фрагментов и предложений [8, 22]. Эти работы важны как переход от жёстких атрибутов к языковому условию, но они ещё не решают задачу прямой многодорожечной MIDI-генерации по произвольному описанию.

Дальнейшие подходы различаются тем, как именно связываются текст и музыка. В

*MuseCoco* текст сначала переводится в промежуточные музыкальные атрибуты, после чего отдельная модель генерирует музыку по этим атрибутам [9]. В работах, использующих ABC-нотацию [1], музыка представляется как текстово-совместимая строка, что упрощает применение языковых моделей [20, 21]. Однако ABC не совпадает с прямой многодорожечной MIDI-генерацией. Для прикладного редактирования и анализа инструментальных партий MIDI остаётся более естественным форматом.

Современная задача прямого преобразования текста в MIDI опирается на специальные корпуса и токенизированные музыкальные представления. Крупные MIDI-корпуса, такие как *Lakh MIDI Dataset*, дают исходный музыкальный материал, но сами по себе почти не содержат языковых описаний [13]. Эту проблему закрывают специализированные ресурсы: *MidiCaps* содержит текстовые описания MIDI-файлов, а *Text2midi* опирается на предварительное обучение на символьной музыке и последующее дообучение на парах “текст–MIDI” [10, 2]. Близкие системы, такие как *ChatMusician* и *MeloTrans*, показывают, что языковые модели и архитектуры преобразователей могут работать с символьной музыкой, но при этом выбор представления и способ обучения существенно влияют на управляемость результата [21, 18].

Главные ограничения существующих решений связаны с данными и структурой музыки. Парные наборы “текст–MIDI” меньше и менее однородны, чем корпуса обычного текста или аудио. Кроме того, хорошее предсказание локальных токенов не гарантирует согласованности целого фрагмента: модель может создавать лишние дорожки, чрезмерно плотную фактуру, слабую гармоническую поддержку или материал, слабо соответствующий высокоуровневому смыслу запроса. Эти ограничения подводят к задаче последующего согласования модели с более сложными критериями качества.

### 3 Мотивация последующего дообучения

При обычном контролируемом дообучении модель учится предсказывать следующий токен по уже сгенерированному контексту. Для text-to-midi это важно: такая цель помогает модели сохранять синтаксис MIDI-представления и не разрушать формат последовательности. Однако качество музыки не сводится к локальной вероятности отдельных токенов. Готовый MIDI-фрагмент оценивается целиком: насколько он тонально согласован, насколько устойчив его ритм, не распадаются ли партии мелодии и сопровождения, соответствует ли результат текстовому описанию.

После базового обучения остаётся задача согласовать модель с музыкальными кри-

териями, которые проявляются только на уровне целого фрагмента. Похожая логика встречается и в других работах: *RL-Duet* рассматривает генерацию аккомпанемента как задачу обучения с подкреплением [6], *MusicRL* использует человеческие предпочтения для text-to-audio генерации [3], а *NotaGen* и *SMART* показывают применимость внешних критериев к символьной музыке [17, 7]. Для text-to-midi близкий подход предложен в *Text2midi-InferAlign*, где награда включается уже на этапе поиска при генерации [14].

В этой работе согласование выполняется поверх уже обученной text-to-midi модели. Для одного запроса генерируется несколько вариантов, каждый вариант оценивается как завершённый MIDI-фрагмент, после чего модель обновляется в сторону относительно более удачных генераций. Для такой постановки подходит GRPO: метод сравнивает ответы внутри одной группы и не требует обучения отдельной модели ценности.

## 4 Предлагаемый подход

### 4.1 Постановка задачи и общая идея

Исходная text-to-midi модель не обучается заново. Дообучение применяется как надстройка над уже обученным генератором и использует дополнительные критерии качества. Для MIDI это существенно: локальная корректность токенов ещё не означает, что весь фрагмент тонально, ритмически и фактурно согласован. Награда поэтому вычисляется после декодирования полной музыкальной последовательности.

Для одного текстового запроса модель генерирует несколько MIDI-кандидатов. Затем кандидаты оцениваются метриками на основе правил или внешним критиком, а параметры модели обновляются по относительному качеству вариантов внутри группы. Такая постановка близка к согласованию с предпочтениями в музыкальной генерации [3, 7] и к последующему согласованию text-to-midi моделей [14].

### 4.2 Базовая модель Text2midi

Исходным генератором служит модель семейства *Text2midi*, предназначенная для прямого преобразования текстового описания в символьную музыкальную последовательность [2]. На вход модель получает текстовый запрос на естественном языке. В запросе могут быть указаны такие свойства, как жанр, настроение, темп, размер, тональность, инструментальный состав и общая фактура. На выходе модель авторегрессионно порождает последовательность музыкальных токенов, которая затем декодируется в MIDI-файл.




Рис. 4.1: Схема архитектуры Text2midi [2].

В дальнейшем модель трактуется как условная политика  $\pi_{\theta}(y \mid x)$ , где  $x$  — текстовый запрос, а  $y$  — сгенерированная MIDI-последовательность. Базовая модель уже умеет порождать валидные MIDI, но может создавать лишние дорожки, слишком плотные фрагменты, большое число ударных событий или материал, слабо согласованный с текстовым запросом. Дообучение должно сместить распределение ответов в сторону более предпочтительных кандидатов, не разрушая исходную способность генерировать символьную музыку.

### 4.3 GRPO как схема последующего дообучения

Для последующего дообучения выбран *Group Relative Policy Optimization* (GRPO) [15]. В text-to-MIDI эта схема удобна по двум причинам: качество фрагмента оценивается после завершения генерации, а один запрос допускает несколько музыкально корректных ответов. GRPO не требует единственного эталона; вместо этого он сравнивает ответы модели между собой и усиливает варианты с более высокой оценкой внутри группы.

Пусть  $q$  обозначает текстовый запрос, а  $o_i$  —  $i$ -ю сгенерированную MIDI-последовательность. На каждом шаге текущая политика, зафиксированная на момент генерации, порождает группу из  $G$  ответов:

$$\{o_i\}_{i=1}^G \sim \pi_{\theta_{\text{old}}}(O \mid q).$$

Каждый ответ декодируется в MIDI и получает скалярную награду  $r_i = R(q, o_i)$ . Награда



вычисляется для всей последовательности: её источником могут быть музыкальные правила, оценка внешнего критика или их комбинация. Относительное преимущество ответа определяется нормировкой наград внутри группы:

$$\hat{A}_i = \frac{r_i - \bar{r}}{s_r + \varepsilon_A}, \quad \bar{r} = \frac{1}{G} \sum_{j=1}^G r_j, \quad s_r = \text{std}(r_1, \dots, r_G).$$

Так как награда относится к завершённому MIDI-фрагменту, одно и то же значение  $\hat{A}_i$  применяется ко всем токенам последовательности  $o_i$ . Если в одном шаге используется несколько запросов, нормировка выполняется отдельно для группы каждого запроса.

Для токена  $o_{i,t}$  вводится отношение вероятностей новой и старой политики:

$$\rho_{i,t}(\theta) = \frac{\pi_\theta(o_{i,t} \mid q, o_{i,<t})}{\pi_{\theta_{\text{old}}}(o_{i,t} \mid q, o_{i,<t})}.$$

Отношение показывает, насколько обновляемая модель изменила вероятность токена относительно политики, использованной при генерации текущей группы. Для ограничения размера обновления применяется отсечение по интервалу  $[1 - \epsilon, 1 + \epsilon]$ . В реализации минимизируется следующая функция потерь:

$$\mathcal{L}_{\text{GRPO}} = \frac{1}{\sum_{i,t} m_{i,t}} \sum_{i,t} m_{i,t} \left( -\min(\rho_{i,t}(\theta) \hat{A}_i, \text{clip}(\rho_{i,t}(\theta), 1 - \epsilon, 1 + \epsilon) \hat{A}_i) + \beta D_{i,t} \right),$$

где  $m_{i,t}$  — маска валидных токенов,  $\epsilon$  задаёт допустимое изменение политики за один шаг, а  $\beta$  определяет вес регуляризации. Слагаемое  $D_{i,t}$  удерживает модель рядом с фиксированной опорной моделью  $\pi_{\text{ref}}$ :

$$D_{i,t} = \frac{\pi_{\text{ref}}(o_{i,t} \mid q, o_{i,<t})}{\pi_\theta(o_{i,t} \mid q, o_{i,<t})} - \log \frac{\pi_{\text{ref}}(o_{i,t} \mid q, o_{i,<t})}{\pi_\theta(o_{i,t} \mid q, o_{i,<t})} - 1.$$

На практике эта величина вычисляется через логарифмы вероятностей токенов. Если ответ имеет положительное относительное преимущество, обновление увеличивает вероятность составляющих его токенов; если преимущество отрицательное, вероятность таких токенов уменьшается. KL-регуляризация удерживает модель от слишком далёкого отклонения от исходного генератора.

Особенности применения GRPO к text-to-MIDI приведены в таблице [4.1](#).

Таблица 4.1: Особенности применения GRPO к задаче text-to-MIDI

| Элемент                | Реализация в работе                                                                            |
|------------------------|------------------------------------------------------------------------------------------------|
| Единица сравнения      | Завершённая MIDI-последовательность, полученная после декодирования токенов.                   |
| Группа ответов         | Несколько вариантов для одного текстового запроса; преимущества считаются внутри этой группы.  |
| Награда                | Скалярная оценка MIDI-фрагмента, вычисляемая правилами, критиком или их комбинацией.           |
| Сигнал критика         | В экспериментах используется сырая оценка критика, ранг внутри группы или доля попарных побед. |
| Ограничение обновления | Отсечение отношения вероятностей снижает риск резкого изменения политики.                      |
| Опорная модель         | KL-слагаемое ограничивает отклонение от исходного генератора.                                  |
| Валидность             | Невалидные или вырожденные MIDI-фрагменты получают штраф и не должны усиливаться при обучении. |

## 4.4 Один шаг обучения в реализованной процедуре

Процедура обучения строится вокруг одного итерационного шага GRPO. На вход шага поступает один или несколько текстовых запросов. В зависимости от конфигурации они могут выбираться из датасета, генерироваться синтетически по шаблону или фиксироваться заранее для диагностического эксперимента. Для каждого запроса модель генерирует несколько независимых кандидатов с одинаковым текстовым условием. Один шаг обучения поэтому содержит не отдельный ответ модели, а группу вариантов для последующего сравнения.

Стадии одного шага сведены в таблицу 4.2. Ключевая особенность процедуры состоит в отложенной награде: качество оценивается не во время выбора отдельного токена, а после декодирования всей последовательности.

В реализации дополнительно сохраняются служебные артефакты каждого шага: тексты запросов, MIDI-файлы сгенерированных кандидатов, значения компонент награды, статистика валидности, контрольные точки модели и метрики обучения. Такие артефакты нужны не только для воспроизводимости, но и для анализа поведения модели. В задачах музыкальной генерации численная награда не всегда полностью объясняет воспринимаемое качество, поэтому возможность прослушать сохранённые MIDI и сопоставить их с компонентами награды входит в экспериментальную процедуру.

Таблица 4.2: Один шаг GRPO-дообучения в реализованной процедуре

| Этап | Операция                 | Назначение                                                                               |
|------|--------------------------|------------------------------------------------------------------------------------------|
| 1    | Выбор запроса            | Задаёт текстовое условие, для которого будет построена группа кандидатов.                |
| 2    | Генерация кандидатов     | Модель порождает несколько MIDI-кандидатов при одном и том же условии.                   |
| 3    | Декодирование            | Токены преобразуются в музыкальное представление и MIDI-файл.                            |
| 4    | Вычисление награды       | Кандидат оценивается компонентами на основе правил или внешним критиком.                 |
| 5    | Нормировка внутри группы | Награды превращаются в относительные преимущества кандидатов.                            |
| 6    | Обновление GRPO          | Обновляются обучаемые параметры с отсечением отношения вероятностей и KL-регуляризацией. |

## 4.5 Настройка обучаемых параметров модели

Полное обновление всех весов в режиме обучения с подкреплением дорого и рискованно: награда шумна, а сильное изменение параметров может ухудшить валидность MIDI. По этой причине используются ограниченные режимы настройки параметров (таблица 4.3).

Таблица 4.3: Режимы настройки обучаемых параметров

| Режим                       | Что обучается                                       | Роль в экспериментах                                     |
|-----------------------------|-----------------------------------------------------|----------------------------------------------------------|
| LoRA-адаптация [5]          | Низкоранговые добавки к выбранным линейным слоям    | Основной экономичный режим для GRPO-дообучения.          |
| Прямое частичное дообучение | Непосредственно выбранные параметры исходной модели | Более сильный, но потенциально менее устойчивый вариант. |

На практике основным стал вариант LoRA только в FFN-блоках: низкоранговые добавки подключаются к слоям декодера `linear1` и `linear2`. Этот режим меняет распределение музыкальных токенов, но оставляет большую часть модели замороженной. Прямое частичное дообучение рассматривается как более сильный вариант, требующий меньшего значения скорости обучения и более строгого контроля KL.

## 4.6 Формирование текстовых запросов

Текстовый запрос определяет группу кандидатов, внутри которой нормируются награды. Он влияет не только на генерацию, но и на разброс обучающего сигнала. В экспериментах

используются короткие шаблонные запросы с явно заданными атрибутами:

A moderate warm folk piece in C major at 96 BPM,  
with a 4/4 time signature. Use piano for the lead melody  
and acoustic guitar for steady accompaniment.

## 4.7 Стратегия выбора запросов для обучения

В экспериментах предусмотрены несколько режимов подачи текстовых запросов (таблица 4.4). Фиксированный запрос нужен для диагностики обучаемости сигнала награды, а более широкие режимы — для проверки обобщения.

Таблица 4.4: Режимы формирования текстовых запросов в GRPO-экспериментах

| Режим                      | Что фиксируется                              | Зачем используется                         |
|----------------------------|----------------------------------------------|--------------------------------------------|
| Фиксированный запрос       | Все текстовые атрибуты постоянны             | Диагностика обучаемости сигнала награды.   |
| Случайные запросы          | Атрибуты случайно выбираются из шаблона      | Проверка обобщения на разные условия.      |
| Учебная последовательность | Пространство запросов расширяется постепенно | Снижение шума и плавное усложнение задачи. |
| Смешанный режим            | Часть запросов фиксирована, часть случайна   | Совмещение диагностики и обобщения.        |

Дополнительно вводится учебная последовательность: сначала фиксируется простой запрос, затем поэтапно меняются тональность, размер и стиль. Такой порядок уменьшает разброс награды между шагами и помогает проверить, не забывает ли модель уже освоенное поведение.

## 4.8 Проектирование функции награды

Функция награды подбиралась итеративно. Сначала проверялись интерпретируемые MIDI-правила, затем критик v1 и критик v2, после этого смешанные схемы. Подход согласуется с работами, где обучение с подкреплением применяется к музыкальной генерации через внешние эстетические или предпочтительные оценки [6, 3, 7]. Семейства сигналов награды приведены в таблице 4.5.

Таблица 4.5: Семейства функций награды

| Семейство          | Источник оценки                        | Роль в работе                                          |
|--------------------|----------------------------------------|--------------------------------------------------------|
| Символьные правила | Метрики, вычисляемые по MIDI-структуре | Контроль интерпретируемых музыкальных свойств.         |
| Сигналы критика    | Критик v1/v2                           | Приближение более сложного музыкального предпочтения.  |
| Смешанные схемы    | Взвешенная комбинация правил и критика | Стабилизация оценки критика через простые ограничения. |

## 4.9 Структура используемых компонент награды

### 4.9.1 Общие обозначения и нормировка

Все компоненты на основе правил вычисляются после декодирования токенов в символьную MIDI-структуру. Обозначим множество нот через  $N$ , число нот через  $|N|$ , длительность фрагмента в долях через  $D$ , число непустых дорожек через  $C$ , долю барабанных нот через  $\rho_d$ , а текстовый запрос через  $x$ . Для мягких ограничений используется треугольная нормировка:

$$T(z; l, c, h) = \begin{cases} 0, & z \leq l \text{ или } z \geq h, \\ \frac{z-l}{c-l}, & l < z < c, \\ 1, & z = c, \\ \frac{h-z}{h-c}, & c < z < h. \end{cases}$$

Эта функция задаёт целевой диапазон значений. Максимальная награда достигается в точке  $c$ ; отклонение в сторону слишком малых или слишком больших значений линейно уменьшает вклад соответствующей компоненты.

### 4.9.2 Тональная согласованность

Компонента тональности использует длительно-взвешенный профиль высот  $p$  и сравнивает его с профилем тональности, заданной текстовым запросом. Если  $k_x$  — целевой профиль, то

$$a = \frac{\text{corr}(p, k_x) + 1}{2}, \quad b = \frac{\text{corr}(p, k_x) - \max_{k \neq k_x} \text{corr}(p, k) + 1}{2},$$

$$R_{\text{key}} = \text{clip}(0.75a + 0.25b, 0, 1).$$

Первое слагаемое отражает абсолютное совпадение с целевой тональностью, второе — отделимость целевой тональности от альтернативных тональностей.

### 4.9.3 Метрическая организация

Компонента метра оценивает не только записанный размер, но и расположение акцентов в нотном материале. Для каждого кандидата вычисляется соответствие  $f_m$  нескольким метрическим шаблонам, после чего целевой размер из текстового запроса получает оценку

$$R_{\text{meter}} = \text{clip}\left(0.7 \frac{f_x}{\max_m f_m} + 0.3 f_x, 0, 1\right).$$

Эта формула учитывает абсолютную выраженность целевого метра и его относительное преимущество перед другими возможными размерами.

### 4.9.4 Длительность и плотность нот

Компоненты длительности и плотности также задаются через треугольную нормировку:

$$R_{\text{dur}} = T(D; 8, 64, 160), \quad R_{\text{dens}} = T\left(\frac{|N|}{\max(D, 1)}; l, c, h\right).$$

Компонента  $R_{\text{dur}}$  снижает награду для слишком коротких фрагментов и чрезмерно длинных артефактов. Компонента  $R_{\text{dens}}$  контролирует число нот на одну долю. Параметры  $l, c, h$  задаются в конфигурации эксперимента; так можно отдельно исследовать обычную и умеренную плотность.

### 4.9.5 Дорожки и ударные инструменты

Аранжировочные ограничения задаются мягкими функциями. Компонента числа дорожек поощряет непустые MIDI с числом дорожек не больше  $C_{\text{max}}$ , а при превышении лимита линейно убывает. Для ударных используется доля барабанных нот:

$$R_{\text{drum}} = \begin{cases} 1, & \rho_d \leq a, \\ 0, & \rho_d \geq b, \\ 1 - \frac{\rho_d - a}{b - a}, & a < \rho_d < b. \end{cases}$$

Такое правило не запрещает ударные полностью, но снижает награду, если они начинают доминировать в MIDI-фрагменте.

#### 4.9.6 Валидность и внешний критик

Проверка валидности служит защитным механизмом. Если MIDI не декодируется, содержит слишком мало нот, слишком короткий фрагмент или чрезмерное повторение одной высоты, выставляется индикатор  $I_{\text{bad}} = 1$ . В экспериментах с внешним критиком дополнительно вводится сигнал  $R_{\text{critic}}$ : сырая оценка, ранг внутри группы или доля попарных побед кандидата над другими вариантами.

#### 4.9.7 Итоговая функция награды

Итоговая награда задаётся как взвешенная сумма активных компонент:

$$R(x, y) = \begin{cases} -p_{\text{bad}}, & I_{\text{bad}}(y) = 1 \text{ и включён жёсткий фильтр,} \\ \sum_k \lambda_k R_k(x, y) + \lambda_c R_{\text{critic}}(x, y), & \text{иначе.} \end{cases}$$

Здесь  $p_{\text{bad}}$  — штраф за невалидный MIDI,  $\lambda_k$  — веса компонент на основе правил, а  $\lambda_c$  — вес внешнего критика. В режиме обучения по критик у ранговый сигнал особенно полезен тогда, когда абсолютные значения критика плохо калиброваны, но порядок кандидатов достаточно информативен.

#### 4.10 Конфликты между компонентами награды

Добавление новых правил не всегда улучшает обучение: компоненты награды могут конфликтовать. Это проверялось в пробных экспериментах с разными наборами компонент: тональностью и метром, плотностью нот, ограничениями на дорожки, запретом ударных и сигналами критика. После этих запусков часть бинарных правил была заменена мягкими метриками, а веса наиболее жёстких компонент были снижены. Выявленные конфликты приведены в таблице 4.6.

Состав функции награды уточнялся эмпирически: анализировались не только суммарный сигнал и вклад отдельных компонент, но и сохранённые MIDI-примеры.

#### 4.11 Ожидаемые преимущества и исследовательские гипотезы

Гипотезы работы сведены в таблицу 4.7.

Таблица 4.6: Типичные конфликты между компонентами награды

| Конфликт                            | Причина                                                                             | Практическое решение                                 |
|-------------------------------------|-------------------------------------------------------------------------------------|------------------------------------------------------|
| Плотность и естественность          | Высокая плотность улучшает формальную заполненность, но может звучать перегруженно. | Переход к умеренной плотности.                       |
| Метр и свобода фразы                | Шаблон метра помогает контролю, но может усиливать механичность.                    | Ослабление веса или временное отключение компоненты. |
| Запрет барабанов и обучаемость      | Бинарный сигнал часто одинаков для всех кандидатов.                                 | Замена на долю барабанных нот.                       |
| Число дорожек и полнота аранжировки | Жёсткое ограничение упрощает MIDI, но может удалить содержательные партии.          | Мягкие ограничения и анализ сохранённых MIDI.        |

Таблица 4.7: Ожидаемые эффекты предлагаемого подхода

| Гипотеза                                        | Ожидаемый эффект                                                                                  |
|-------------------------------------------------|---------------------------------------------------------------------------------------------------|
| GRPO применим к text-to-midi                    | Модель сможет усиливать более удачные MIDI-кандидаты без эталонной последовательности.            |
| Ограниченная настройка параметров достаточна    | LoRA или частичное дообучение смогут изменить поведение модели без полного обновления всех весов. |
| Мягкие компоненты награды лучше бинарных        | Непрерывные сигналы будут чаще различать кандидатов внутри группы.                                |
| Узкое распределение запросов снижает шум        | Фиксированный запрос и учебная последовательность позволят яснее увидеть динамику обучения.       |
| Внешний критик может служить источником награды | Сигнал критика позволит согласовывать модель с более сложными критериями качества.                |

## 5 Экспериментальная часть

### 5.1 Цели экспериментального исследования

Экспериментальная часть проверяет, можно ли использовать предложенную схему для последующего дообучения text-to-MIDI модели. В отличие от стандартного обучения с эталонной MIDI-последовательностью, здесь модель получает только текстовый запрос и несколько собственных вариантов ответа. Главный вопрос состоит в том, достаточно ли относительных оценок MIDI-кандидатов для устойчивого обновления модели.

Первая цель — проверить саму возможность дообучения с подкреплением для символической музыкальной генерации. Необходимо установить, приводит ли обновление параметров по групповым оценкам к изменению поведения модели, не разрушая при этом способность генерировать валидные MIDI-файлы. Для этого анализируются значения итоговой награды, доля валидных генераций, характер ошибок декодирования, динамика KL-штрафа



и изменение отдельных компонент награды.

Вторая цель — сравнить источники награды: интерпретируемые правила, критик  $v1/v2$  и смешанные схемы. Компоненты на основе правил контролируют простые музыкальные свойства: тональность, метр, длительность, плотность нот и долю ударных событий. Критик, напротив, должен приближать более сложное предпочтение, которое трудно выразить набором простых формул. В этих экспериментах проверяется, какие сигналы дают различные оценки внутри группы кандидатов и какие из них приводят к более устойчивому обновлению модели.

Третья цель — выбрать режим адаптации параметров. Полное дообучение модели в режиме обучения с подкреплением вычислительно дорого и может приводить к нестабильным изменениям политики. Сравнение ведётся между более ограниченными режимами: LoRA-адаптацией выбранных слоёв, настройкой FFN-блоков и частичным дообучением. Здесь важен не только рост награды, но и устойчивость обучения: отсутствие резких скачков функции потерь, чрезмерного роста KL и деградации качества MIDI.

Ещё одна задача — сопоставить внутренние метрики обучения с внешней оценкой качества. Рост суммарной награды сам по себе не гарантирует улучшения музыкального результата: модель может переоптимизироваться под отдельную компоненту, например чрезмерно увеличить плотность нот или механически следовать метрическому шаблону. Итоговая оценка строится не только по логам обучения, но и по построенному А/В-сравнению базовой и дообученной модели, а также по оценкам внешней модели-оценщика.

## 5.2 Инфраструктура и программная реализация

Экспериментальная инфраструктура реализована как расширение открытого проекта Text2MIDI<sup>1</sup>. В кодовую базу добавлены процедура последующего GRPO-дообучения, модуль вычисления наград, система конфигураций и средства сохранения результатов. Реализация организована модульно: отдельно задаются конфигурации запусков, процедура обучения, компоненты функции награды и инструменты последующего анализа.

Программная часть написана на языке Python [12], а обучение нейросетевых моделей и вычисление градиентов выполняются с использованием PyTorch [11]. Этот стек даёт возможность гибко управлять генерацией последовательностей, повторно вычислять логарифмы вероятностей токенов для GRPO и сохранять состояние оптимизатора между запусками.

Обучение запускается по имени эксперимента. Для каждого запуска создаётся YAML-

---

<sup>1</sup>blank

конфигурация, в которой фиксируются параметры GRPO: число текстовых запросов на шаг, число генерируемых кандидатов, максимальная длина генерации, скорость обучения, веса компонент награды и режим адаптации параметров модели. Часть параметров можно переопределить из командной строки; это упрощает проведение серий сопоставимых экспериментов.

Во время обучения сохраняются контрольные точки модели, значения отдельных компонент награды, служебные метрики оптимизации и, при необходимости, промежуточные MIDI-кандидаты. Логирование ведётся в Weights & Biases [19]: по этим логам сопоставляются динамика суммарной награды с поведением отдельных компонент, KL-штрафом, функцией потерь, нормами градиентов и статистикой валидности. Логи запусков и связанные с ними артефакты экспериментов доступны в материалах репозитория.

### 5.3 Семейства исследуемых конфигураций

Эксперименты организованы как несколько семейств конфигураций, а не как один длинный запуск. Такое разделение помогает отдельно оценить влияние источника награды, длины генерации, способа выбора текстовых запросов и набора обучаемых параметров. Базовая модель во всех случаях остаётся одной и той же, а различия между запусками задаются через конфигурационные файлы.

Первое семейство составляют запуски с наградами на основе явно заданных музыкальных правил. В них модель получает сигнал за соответствие тональности, метрической структуре, умеренной плотности нот, балансу длительности и ограничению доли ударных событий. Эти эксперименты показывают, может ли GRPO улучшать формальные свойства MIDI без привлечения обученного музыкального критика.

Во втором семействе основной наградой служит только критик выбранной версии. В таких запусках качество не задаётся вручную в виде отдельных компонент; модель получает скалярный сигнал, полученный из ранжирования нескольких сгенерированных вариантов. Здесь проверяется, достаточно ли обобщённого сигнала качества для устойчивого дообучения генератора.

Третье семейство объединяет оба подхода: часть награды задаётся правилами, а часть — критиком. Такие конфигурации рассматриваются как компромисс между интерпретируемостью ручных признаков и более общей оценкой музыкальности. Предварительные запуски показали, что слишком большое число одновременно активных компонент может давать конфликтующие градиенты; поэтому смешанные конфигурации проверялись в нескольких

вариантах с разными весами.

Также рассматривались эксперименты с отбором дорожек после генерации. В них из исходного MIDI выбирались наиболее информативные неударные дорожки, после чего уже этот вариант передавался в вычисление награды. Эти запуски отделяют качество музыкального материала от шума, возникающего из-за пустых, слишком коротких или преимущественно ударных дорожек. Позднее проверялись и конфигурации без такого отбора, чтобы оценить, способна ли модель научиться генерировать более подходящую структуру напрямую.

Ещё одна группа экспериментов связана с ограничением пространства текстовых запросов. Вместо немедленного обучения на широком наборе описаний использовались фиксированный запрос и небольшой учебный набор, в котором постепенно менялись тональность, размер и стиль. Учебная последовательность нужна для диагностики: если модель не демонстрирует изменений даже на узком классе запросов, то расширение набора описаний не устраняет проблему, а лишь увеличивает шум оценки.

Таблица 5.1: Основные семейства экспериментальных конфигураций

| Семейство                           | Основная идея                                                                              | Что проверяется                                                              |
|-------------------------------------|--------------------------------------------------------------------------------------------|------------------------------------------------------------------------------|
| Правила                             | Награда из музыкальных признаков: тональность, метр, плотность, длительность, доля ударных | Способность GRPO улучшать явно заданные свойства MIDI                        |
| Критик v1/v2                        | Награда строится по ранжированию сгенерированных вариантов                                 | Достаточность обученного сигнала качества без ручных правил                  |
| Правила + критик v1/v2              | Сумма интерпретируемых компонент и оценки критика                                          | Баланс между устойчивостью правил и обобщённой музыкальной оценкой           |
| Отбор дорожек                       | Награда считается после выбора информативных неударных дорожек                             | Влияние пустых и шумовых дорожек на обучение                                 |
| Учебная последовательность запросов | Постепенное усложнение: базовое описание, тональность, размер, стиль                       | Возможность увидеть эффект обучения на узком и контролируемом наборе условий |

## 5.4 Конфигурации текстовых запросов и режимов генерации

В GRPO один шаг обучения строится не по отдельной сгенерированной последовательности, а по группе кандидатов для одного или нескольких текстовых описаний. Если на шаге используется  $P$  описаний и для каждого описания генерируется  $G$  вариантов, то всего

на шаг получается  $P \cdot G$  MIDI-кандидатов. Награды нормируются внутри группы вариантов, относящихся к одному и тому же описанию, поэтому выбор  $P$  и  $G$  напрямую влияет на шумность обучающего сигнала.

В начальных экспериментах использовались более широкие наборы описаний: несколько запросов на шаг и небольшое число кандидатов для каждого из них. Этот режим быстрее покрывает разные музыкальные условия, но увеличивает разброс наград: модель одновременно видит разные тональности, размеры, стили и требования к фактуре. Для ранней проверки работоспособности алгоритма это полезно, однако по таким кривым сложнее понять, действительно ли модель подстраивается под награду или изменения объясняются случайностью генерации.

В последующих диагностических запусках пространство запросов было сужено. Главный диагностический режим — один запрос на шаг и увеличенное число кандидатов. Например, в конфигурациях с 18 вариантами на один запрос один шаг обучения содержит 18 MIDI-кандидатов, а в запусках с критиком — 25 кандидатов. Это делает относительное сравнение внутри группы более устойчивым: все варианты отвечают одному и тому же текстовому условию, а различия в награде сильнее связаны с качеством самой генерации.

Максимальная длина генерации задаёт верхнюю границу числа генерируемых токенов. Для быстрых диагностических экспериментов использовалась длина 800: она даёт достаточно содержательный музыкальный фрагмент, но не делает генерацию чрезмерно дорогой. Проверялись и более длинные варианты, однако увеличение длины заметно повышает время одного шага и может усиливать шум награды, если модель начинает генерировать слишком плотный или неустойчивый материал.

Параметр `generation_chunk_size` отвечает только за техническое разбиение генерации на части. Он не меняет число кандидатов в GRPO-группе, но помогает подстроить запуск под доступную видеопамять. Параметр `update_mini_batch` аналогично задаёт размер части кандидатов, используемой при вычислении обновления. В основных диагностических запусках оба параметра выбирались равными числу кандидатов, чтобы весь набор вариантов для одного запроса обрабатывался без дополнительного дробления.

Для проверки способности модели удерживать простые изменения условий была добавлена учебная последовательность запросов. Она состоит из четырёх этапов: сначала фиксируется базовое описание, затем меняется тональность, после этого размер, а на последнем этапе — стиль. При переходе к новым этапам часть ранних запросов повторяется, чтобы уменьшить забывание уже освоенных условий. Этот режим не предназначен для финальной оценки качества на широком наборе описаний; его задача — показать, появляется ли

управляемое изменение поведения модели в простой и контролируемой постановке.

## 5.5 Сравнимые стратегии адаптации параметров

Исходная Text2MIDI-модель уже обучена генерировать MIDI, поэтому полное переобучение всех параметров не проводится. Вместо этого сравниваются ограниченные режимы настройки, в которых изменяется только небольшая часть модели. Такой выбор снижает вычислительные требования и уменьшает риск разрушить уже выученную способность генерировать синтаксически корректные MIDI-последовательности.

Главный режим основан на LoRA [5]: веса исходной модели замораживаются, а к выбранным линейным преобразованиям добавляются обучаемые низкоранговые матрицы. В экспериментах проверялись три варианта такого подключения. Первый вариант изменяет только слои внимания (`to_qkv`, `to_out`); он потенциально влияет на связи между токенами и структуру последовательности. Второй вариант изменяет только FFN-блоки декодера (`linear1`, `linear2`); он оказался более удобным для локального смещения распределения музыкальных токенов без резкой перестройки внимания. Третий вариант объединяет оба набора слоёв и даёт модели больше свободы, но требует более осторожного выбора скорости обучения и KL-ограничения.

Также рассматривалось прямое частичное дообучение. В этом режиме LoRA-добавки не используются: выбранные параметры самой модели становятся обучаемыми, а остальные веса остаются замороженными. Этот вариант сильнее воздействует на модель, из-за чего для него применялись меньшие значения скорости обучения и более строгий контроль KL. На практике он полезен как проверка того, не ограничивает ли LoRA слишком сильно пространство возможных изменений.

Для итоговых серий наиболее важным оказался режим LoRA на FFN-блоках. Он сохраняет базовую структуру генератора и при этом заметно меняет вероятности локальных музыкальных решений: выбор длительностей, плотность нот, распределение инструментальных событий и реакцию на сигнал критика. В итоге этот режим использовался в учебных последовательностях запросов и в поздних экспериментах с фиксированным запросом.

## 5.6 Внутренние метрики и диагностика обучения

Во время обучения фиксируются итоговая награда и значения отдельных компонент. По ним можно понять, за счёт чего меняется поведение модели: например, растёт ли награда из-за лучшего соответствия тональности, из-за снижения доли ударных событий или из-

Таблица 5.2: Сравнимые режимы настройки параметров

| Режим                        | Обучаемые параметры                         | Назначение в экспериментах                                                      |
|------------------------------|---------------------------------------------|---------------------------------------------------------------------------------|
| LoRA на слоях внимания       | <code>to_qkv</code> , <code>to_out</code>   | Проверка влияния на зависимости между токенами и организацию последовательности |
| LoRA на FFN                  | <code>linear1</code> , <code>linear2</code> | Основной устойчивый режим для поздних запусков с правилами и критиком           |
| LoRA на слоях внимания и FFN | Все перечисленные выше слои                 | Более гибкая, но менее стабильная настройка распределения генерации             |
| Прямое частичное дообучение  | Выбранные параметры исходной модели         | Проверка более сильного вмешательства при меньшей скорости обучения             |

за сигнала обученного критика. Для смешанных функций награды такой разбор особенно важен, поскольку рост одной компоненты может сопровождаться ухудшением другой.

Также отслеживаются служебные метрики оптимизации: функция потерь, величина KL-расхождения с исходной политикой, норма градиента и отношение вероятностей новой и старой политики. Эти величины используются как признаки устойчивости обучения. Например, резкий рост KL показывает, что модель слишком далеко отходит от исходного распределения, а большие скачки нормы градиента могут указывать на слишком высокую скорость обучения или слишком шумную награду.

Также учитываются показатели валидности MIDI-последовательностей и частота пропущенных обновлений, если соответствующая проверка включена в конфигурации. Они помогают отделить настоящий рост качества от ситуаций, когда модель получает высокую награду на технически неудачных или плохо декодируемых последовательностях.

Внутренние метрики не рассматриваются как окончательная оценка музыкального качества. Они показывают ход оптимизации, но не гарантируют, что результат стал лучше на слух. Вместе с ними проводится внешнее сравнение с базовой моделью.

## 5.7 Построение внешней оценки качества

Итоговая проверка качества проводится отдельно от процесса обучения. Награда участвует в обновлении модели и сама по себе не является независимым критерием. После завершения выбранного запуска сравниваются генерации базовой модели и дообученной версии на одном и том же наборе текстовых запросов.

Для каждого запроса генерируется несколько MIDI-вариантов от обеих моделей. Ре-

зультаты агрегируются двумя способами: по среднему качеству нескольких генераций и по лучшему варианту из группы. Первый показатель отражает стабильность модели, второй — её способность хотя бы иногда выдавать сильный пример.

#### **5.7.1 А/В-сравнение базовой и дообученной модели**

В А/В-сравнении для каждого запроса определяется, какая из двух моделей получила более высокую агрегированную оценку. Затем считается число побед базовой и дообученной модели, доля побед и статистическая значимость по знаковому критерию. Эта схема не требует сравнивать абсолютные значения награды для разных запросов напрямую.

#### **5.7.2 Оценка с помощью внешней языковой модели**

Для дополнительной проверки MIDI переводится в ABC-нотацию [1]. Это представление сохраняет тональность, размер, голоса и последовательность нот, но остаётся текстовым и подходит для передачи в языковую модель. В роли оценщика использовалась модель DeepSeek [4]: ей передавались текстовый запрос и ABC-запись сгенерированного MIDI, после чего возвращались численная оценка и краткое объяснение.

Сравнение также проводится в формате А/В-теста. Для одного и того же запроса сопоставляются оценки генераций базовой и дообученной модели, затем агрегируются победы по запросам. Эта оценка не используется как награда во время обучения; она нужна для независимой проверки того, совпадает ли рост внутренних метрик с внешней музыкальной оценкой.

## **6 Результаты экспериментов**

В этот раздел выносятся численные результаты и графики после завершения финальных запусков. Сначала приводится динамика обучения, затем сравнение моделей и внешняя оценка качества.

### **6.1 Динамика обучения**

На первом этапе проверялось, способен ли предложенный контур GRPO-дообучения изменять поведение text-to-midi модели по завершённомu MIDI-фрагменту, а не только по токенам. Для этого рассматривались запуски с интерпретируемыми наградами, учебной последовательностью prompt-ов и последующим подключением критика. Динамика обучения

показывает, что модель действительно реагирует на внешний сигнал: отдельные компоненты награды начинают изменяться в ожидаемом направлении, а лучшие кандидаты в группе становятся качественнее по заданным критериям.




Рис. 6.1: Динамика компонент награды при обучении по правилам на выбранном текстовом запросе.

На рис. 6.1 показан начальный участок обучения модели на выбранном текстовом запросе. Уже в этом простом режиме видно, что модель подстраивается под награды, заданные на уровне MIDI: усиливается соответствие тональности, снижается доля нежелательных ударных событий, а суммарная награда растёт относительно первых итераций. Такой результат важен как техническая проверка всей схемы: награда вычисляется после декодирования MIDI, но всё равно создаёт обучающий сигнал для языковой модели. Более шумная компонента плотности нот показывает, что не все музыкальные свойства одинаково легко оптимизируются простыми правилами.






Рис. 6.2: Динамика общей награды при поэтапном обучении. Бледная линия показывает фактические значения, синяя — сглаженную динамику, оранжевая — лучшее достигнутое значение.

На рис. 6.2 показан запуск с учебной последовательностью запросов. Вертикальные линии отделяют этапы, на которых изменялись тональность, метрическая структура и стиль. По сравнению с немедленным обучением на разнородных `prompt`-ах такая схема оказалась более удобной для анализа: модель сначала закрепляет поведение на простом запросе, а затем переносит его на близкие варианты. Линия лучшего достигнутого значения показывает, что после перехода к более насыщенным условиям появляются сильные кандидаты, удовлетворяющие нескольким музыкальным ограничениям одновременно. Иными словами, `curriculum` не устраняет полностью шумность GRPO, но делает эксперимент управляемым.




Рис. 6.3: Дообучение по критику v1 после предварительного обучения на правилах. Показан участок до последнего пика оценки критика; синяя линия соответствует фактическим значениям, оранжевая — лучшему достигнутому значению.

На рис. 6.3 отдельно показан этап, где модель продолжает обучение уже по сигналу критика v1. Предварительное обучение на правилах здесь играет роль стабилизации: критик v1 подключается не к полностью исходной модели, а к модели, которая уже частично соблюдает простые музыкальные ограничения. В этом режиме удаётся получить отдельные кандидаты с заметно более высокой оценкой критика v1, что подтверждает полезность последовательной схемы “правила затем критик v1”. При этом сам сигнал критика v1 остаётся более шумным, чем ручные правила; это ограничение подробнее обсуждается в разделе анализа ошибок.




Рис. 6.4: Обучение с критиком v1 на случайных prompt-ах. Показан запуск, в котором широкое распределение запросов привело к неустойчивой динамике общей награды.

Рис. 6.4 приведён как контрольный пример: слишком широкое распределение запросов затрудняет обучение и делает награду менее интерпретируемой. Этот результат полезен методически, поскольку показывает, почему дальнейшие эксперименты были сосредоточены на фиксированном prompt-е и учебной последовательности, а не на случайном смешивании большого числа условий.




Рис. 6.5: Ранний участок обучения с критиком v2 и уменьшенным шагом обучения.

На рис. 6.5 показан запуск, в котором шаг обучения был уменьшен для более осторожной адаптации модели к сигналу критика v2. Такой режим рассматривался как более

консервативный вариант обучения: он не даёт резкого изменения политики, но позволяет проверить, реагирует ли модель на более позднюю версию критика без сильного разрушения исходного поведения.

## 6.2 А/В-сравнение

Для внутреннего сравнения использовались те же MIDI-файлы, что и для последующей внешней оценки: по 900 генераций на модель при одинаковых условиях текстового запроса. Для каждой дообученной модели использовался только тот источник оценки, по которому она обучалась: модели с правилами сравнивались по суммарной награде на основе правил, а модели с критиком — по оценке соответствующего критика. Такое сравнение не смешивает разные цели оптимизации и показывает, улучшилась ли модель именно относительно собственного обучающего сигнала.

На рис. 6.6 показана доля попарных побед дообученной модели над базовой; значение 0.5 соответствует паритету.




Рис. 6.6: А/В-сравнение с базовой моделью по собственному источнику награды. Показана доля попарных побед над базовой моделью.

## 6.3 Оценка внешней языковой моделью

Дополнительно была проведена пилотная оценка внешней языковой моделью DeepSeek v3.2 через API AITunnel. Сравнивались две модели: базовая text-to-midi модель и модель, дообученная по схеме “правила затем критик v1”. MIDI-файлы предварительно переводились

в ABC, после чего в DeepSeek передавался оценочный prompt. В нём модель задавалась как эксперт по символьной музыке и получала инструкцию оценить качество связи мелодии и гармонии: соответствие мелодических нот активным аккордам и тональности, поддержку сильных долей, оправданность диссонансов и хроматизмов, согласованность смены аккордов с ритмом мелодии, а также естественность басового движения. Отдельно указывалось игнорировать качество тембров, сведения, реалистичность инструментов и другие артефакты MIDI-производства. Ответ требовался в формате **Score:** <1-10> и короткого объяснения. Если численная оценка не была извлечена из ответа модели, значение считалось равным 0.

Таблица 6.1: Пилотная внешняя оценка DeepSeek v3.2

| Модель                 | Средняя оценка | Медиана | Максимальная оценка |
|------------------------|----------------|---------|---------------------|
| Базовая модель         | 1.90           | 2.00    | 6.00                |
| Критик v1 после правил | 2.80           | 2.00    | 9.00                |

По средней оценке дообученная модель превосходит базовую на 0.90 балла. Этот результат следует рассматривать как предварительный: объём внешней оценки мал, а отдельные ответы языковой модели могут быть нестабильны. Тем не менее он согласуется с основной гипотезой эксперимента: предварительное обучение на простых правилах может подготовить модель к последующему использованию более сложного сигнала критика.

## 7 Анализ ошибок и ограничений

Несмотря на положительные диагностические результаты, эксперименты выявили ряд ограничений, которые мешают получить устойчивую и крупную победу над базовой моделью. Эти ограничения важны, потому что они показывают не только слабые места конкретных запусков, но и требования к дальнейшему развитию метода.

Первая проблема связана с плотностью нот. Простое поощрение заполненности может быстро привести к переоптимизации: модель начинает генерировать слишком быстрые и перегруженные фрагменты. Формально такие примеры получают высокую оценку по компоненте плотности, но при прослушивании звучат менее естественно. Это показывает, что музыкальная “насыщенность” не сводится к числу нот. Поэтому в поздних конфигурациях максимизация плотности была заменена более осторожной наградой за умеренный диапазон значений.

Вторая проблема связана с ударными и пустыми дорожками. Базовая модель часто создаёт дополнительные дорожки, которые либо почти не содержат нот, либо состоят пре-

имущественно из ударных событий. Это искажает как награду, так и восприятие результата: MIDI может выглядеть насыщенным, хотя содержательная мелодико-гармоническая часть остаётся слабой. Режимы с отбором информативных неударных дорожек частично решают задачу, но одновременно вносят ещё один эвристический слой в обработку результата.

Наиболее существенное ограничение связано с критиком. Он предполагает, что MIDI можно представить как две музыкальные роли: ведущую мелодию и гармоническое сопровождение. Перед оценкой выполнялась проекция исходного MIDI в формат `melody/chords`: сначала выбиралась наиболее мелодическая неударная дорожка по эвристикам высоты, полифонии и поступенного движения, а остальные неударные дорожки объединялись в сопровождение. Если такой вариант давал слишком мало материала, использовалась резервная проекция по событиям, где верхний голос считался мелодией, а остальные ноты — сопровождением.

Такая проекция делает вход критика совместимым с его обучающим форматом, но добавляет шум. Ошибка выбора мелодической дорожки, потеря многоголосной фактуры или неудачное разделение верхнего голоса и аккордовых нот могут изменить оценку независимо от реального качества MIDI. Поэтому запуски только с критиком нельзя трактовать как чистое измерение музыкального качества: они оценивают связку из модели, процедуры проекции и самого критика.

Отдельным недостатком оказалась чувствительность к пространству текстовых запросов. При слишком широком наборе описаний на ранних этапах обучение становится плохо интерпретируемым: модель одновременно получает сигналы по разным тональностям, размерам, стилям и фактурам. В таких условиях суммарная награда не демонстрирует устойчивого роста, а отдельные удачные пики могут быть следствием случайной генерации. Именно поэтому диагностические запуски с одним фиксированным запросом и учебная последовательность оказались более информативными.

Наконец, сохраняется высокая вычислительная стоимость экспериментов. Увеличение максимальной длины генерации даёт потенциально более полный музыкальный фрагмент, но существенно замедляет шаг обучения и может усиливать проблемы с плотностью нот. Длина 800 токенов использовалась как практический компромисс между скоростью диагностики и содержательностью результата, однако для финальной оценки музыкальности требуется проверка и на более длинных фрагментах.

## 8 Заключение

В работе была исследована схема последующего дообучения text-to-MIDI модели по внешним критериям качества. В отличие от обычного контролируемого дообучения, где модель оптимизирует предсказание следующего токена, использованный подход оценивает уже завершённые MIDI-фрагменты. Это позволило работать с теми свойствами, которые проявляются на уровне целой музыкальной последовательности: тональной согласованностью, ритмической устойчивостью, плотностью фактуры, долей ударных событий и общей структурной связностью.

В ходе работы был реализован полный цикл GRPO-дообучения: генерация группы кандидатов для текстового запроса, декодирование MIDI, вычисление награды, обновление LoRA-параметров и последующая диагностика качества. Были исследованы два типа обучающего сигнала. Первый основан на интерпретируемых правилах и позволяет контролировать отдельные свойства MIDI. Второй использует графовый критик, оценивающий музыкально-теоретическую согласованность фрагмента через отношения между мелодией, гармонией и метрической структурой.

Положительным результатом стало то, что в диагностических режимах модель реагировала на выбранный источник награды: rule-based конфигурации улучшали часть формальных музыкальных признаков, а использование более сильного критика после предварительного обучения на правилах дало более благоприятный результат в сравнении с базовой моделью. Это подтверждает основную гипотезу работы: последующее дообучение может смещать распределение генераций в сторону кандидатов, предпочтительных по заданному музыкальному критерию.

В то же время эксперименты показали ограничения подхода. Простые правила могут конфликтовать между собой: например, поощрение плотности нот без дополнительных ограничений приводит к чрезмерно насыщенной фактуре. Качество критика также существенно влияет на результат: слабый или смещённый критик может поощрять формальные признаки, не совпадающие с воспринимаемой музыкальностью. Кроме того, проекция произвольного MIDI в представление мелодии и аккомпанемента добавляет шум, поэтому итоговая оценка зависит не только от сгенерированного фрагмента, но и от процедуры его структурного разбора.

Дальнейшее развитие работы прежде всего требует более надёжной внешней проверки музыкального качества. Помимо автоматических оценок, нужен зрительский тест: слушателям можно предъявлять пары MIDI или аудиорендеров, полученных базовой и дообученной

моделью, и просить выбрать более музыкальный, согласованный с текстовым запросом и целостный вариант. Такой тест покажет, насколько выводы по награде, А/В-сравнению и оценке языковой модели совпадают с человеческим восприятием.

Второе направление связано с улучшением критика. Перспективным является его обучение на более разнообразных парах MIDI, включение отрицательных примеров с типичными ошибками генерации и отдельная проверка согласованности оценок критика с человеческими предпочтениями. Это особенно важно, поскольку именно критик задаёт направление последующего обучения с подкреплением.

Третье направление — построение более полного пространства текстовых запросов. В диагностических экспериментах использовались узкие и контролируемые описания, что удобно для анализа обучаемости, но недостаточно для проверки обобщения. В дальнейшем следует сформировать набор запросов, покрывающий тональности, размеры, темпы, стили, инструментальные составы и типы фактуры. Такой набор позволит оценивать модель не только в узком диагностическом режиме, но и на более широком распределении задач.

Требуется также расширить набор структурных метрик для MIDI. Помимо валидности, плотности нот и доли ударных, полезно анализировать устойчивость мелодической линии, роль аккомпанеента, повторяемость мотивов, распределение регистров, согласованность голосов и соответствие инструментов текстовому описанию. Эти метрики не должны заменять прослушивание, но могут дать более подробную картину того, какие свойства модели действительно улучшаются после GRPO-дообучения.



## Список литературы

- [1] abcnotation.com. *ABC Music Notation*. 2026. URL: <https://abcnotation.com/> (дата обр. 13.05.2026).
- [2] Keshav Bhandari, Abhinaba Roy, Kyra Wang, Geeta Puri, Simon Colton и Dorien Herremans. “Text2midi: Generating Symbolic Music from Captions”. В: *Proceedings of the AAAI Conference on Artificial Intelligence*. Т. 39. 22. 2025, с. 23478—23486. DOI: [10.1609/aaai.v39i22.34516](https://ojs.aaai.org/index.php/AAAI/article/view/34516). URL: <https://ojs.aaai.org/index.php/AAAI/article/view/34516>.
- [3] Geoffrey Cideron, Sertan Girgin, Mauro Verzetti, Damien Vincent, Matej Kastelic, Zalán Borsos, Brian McWilliams, Victor Ungureanu, Olivier Bachem, Olivier Pietquin, Matthieu Geist, Léonard Hussenot, Neil Zeghidour и Andrea Agostinelli. “MusicRL: Aligning Music Generation to Human Preferences”. В: *arXiv preprint arXiv:2402.04229* (2024). URL: <https://arxiv.org/abs/2402.04229>.
- [4] DeepSeek-AI. “DeepSeek-V3 Technical Report”. В: *arXiv preprint arXiv:2412.19437* (2024). URL: <https://arxiv.org/abs/2412.19437>.
- [5] Edward J. Hu, Yelong Shen, Phillip Wallis, Zeyuan Allen-Zhu, Yanzhi Li, Shean Wang, Lu Wang и Weizhu Chen. “LoRA: Low-Rank Adaptation of Large Language Models”. В: *arXiv preprint arXiv:2106.09685* (2021). URL: <https://arxiv.org/abs/2106.09685>.
- [6] Nan Jiang, Sheng Jin, Zhiyao Duan и Changshui Zhang. “RL-Duet: Online Music Accompaniment Generation Using Deep Reinforcement Learning”. В: *Proceedings of the AAAI Conference on Artificial Intelligence*. 2020. URL: <https://arxiv.org/abs/2002.03082>.
- [7] Nicolas Jonason, Luca Casini и Bob L. T. Sturm. “SMART: Tuning a Symbolic Music Generation System with an Audio Domain Aesthetic Reward”. В: *arXiv preprint arXiv:2504.16839* (2025). URL: <https://arxiv.org/abs/2504.16839>.
- [8] Zeqian Ju, Peiling Lu, Xu Tan, Rui Wang, Chen Zhang, Songruoyao Wu, Kejun Zhang, Xiangyang Li, Tao Qin и Tie-Yan Liu. “TeleMelody: Lyric-to-Melody Generation with a Template-Based Two-Stage Method”. В: *arXiv preprint arXiv:2109.09617* (2021). URL: <https://arxiv.org/abs/2109.09617>.
- [9] Peiling Lu, Xin Xu, Chenfei Kang, Botao Yu, Chengyi Xing, Xu Tan и Jiang Bian. “MuseCoco: Generating Symbolic Music from Text”. В: *arXiv preprint arXiv:2306.00110* (2023). URL: <https://arxiv.org/abs/2306.00110>.

- [10] Jan Melechovsky, Abhinaba Roy и Dorien Herremans. “MidiCaps: A Large-Scale MIDI Dataset with Text Captions”. B: *arXiv preprint arXiv:2406.02255* (2024). URL: <https://arxiv.org/abs/2406.02255>.
- [11] Adam Paszke, Sam Gross, Francisco Massa, Adam Lerer, James Bradbury, Gregory Chanan, Trevor Killeen, Zeming Lin, Natalia Gimelshein, Luca Antiga, Alban Desmaison, Andreas Köpf, Edward Yang, Zachary DeVito, Martin Raison, Alykhan Tejani, Sasank Chilamkurthy, Benoit Steiner, Lu Fang, Junjie Bai и Soumith Chintala. “PyTorch: An Imperative Style, High-Performance Deep Learning Library”. B: *Advances in Neural Information Processing Systems*. T. 32. 2019. URL: <https://papers.neurips.cc/paper/9015-pytorch>.
- [12] Python Software Foundation. *Python Language Reference*. 2026. URL: <https://docs.python.org/3/reference/> (дата обр. 13.05.2026).
- [13] Colin Raffel. *The Lakh MIDI Dataset v0.1*. 2016. URL: <https://colinraffel.com/projects/lmd/> (дата обр. 13.05.2026).
- [14] Abhinaba Roy, Geeta Puri и Dorien Herremans. “Text2midi-InferAlign: Improving Symbolic Music Generation with Inference-Time Alignment”. B: *arXiv preprint arXiv:2505.12669* (2025). URL: <https://arxiv.org/abs/2505.12669>.
- [15] Zhihong Shao, Peiyi Wang, Qihao Zhu, Runxin Xu, Junxiao Song, Xiao Bi, Haowei Zhang, Mingchuan Zhang, Y. K. Li, Y. Wu и Daya Guo. “DeepSeekMath: Pushing the Limits of Mathematical Reasoning in Open Language Models”. B: *arXiv preprint arXiv:2402.03300* (2024). URL: <https://arxiv.org/abs/2402.03300>.
- [16] Serkan Sulun, Matthew E. P. Davies и Paula Viana. “Symbolic Music Generation Conditioned on Continuous-Valued Emotions”. B: *IEEE Access* 10 (2022), с. 44617—44626. DOI: [10.1109/ACCESS.2022.3169624](https://doi.org/10.1109/ACCESS.2022.3169624).
- [17] Yashan Wang, Shangda Wu, Jianhuai Hu, Xingjian Du, Yueqi Peng, Yongxin Huang, Shuai Fan, Xiaobing Li, Feng Yu и Maosong Sun. “NotaGen: Advancing Musicality in Symbolic Music Generation with Large Language Model Training Paradigms”. B: *arXiv preprint arXiv:2502.18008* (2025). URL: <https://arxiv.org/abs/2502.18008>.
- [18] Yutian Wang, Wanyin Yang, Zhenrong Dai, Yilong Zhang, Kun Zhao и Hui Wang. “MeloTrans: A Text to Symbolic Music Generation Model Following Human Composition Habit”. B: *arXiv preprint arXiv:2410.13419* (2024). URL: <https://arxiv.org/abs/2410.13419>.
- [19] Weights & Biases. *Weights & Biases*. 2026. URL: <https://wandb.ai/site> (дата обр. 13.05.2026).

- [20] Shangda Wu и Maosong Sun. “Exploring the Efficacy of Pre-trained Checkpoints in Text-to-Music Generation Task”. B: *arXiv preprint arXiv:2211.11216* (2022). URL: <https://arxiv.org/abs/2211.11216>.
- [21] Ruibin Yuan, Hanfeng Lin, Yi Wang, Zeyue Tian, Shangda Wu, Tianhao Shen, Ge Zhang, Yuhang Wu, Cong Liu, Ziya Zhou, Ziyang Ma, Liumeng Xue, Ziyu Wang, Qin Liu, Tianyu Zheng, Yizhi Li, Yinghao Ma, Yiming Liang, Xiaowei Chi, Ruibo Liu, Zili Wang, Pengfei Li, Jingcheng Wu, Chenghua Lin, Qifeng Liu, Tao Jiang, Wenhao Huang, Wenhui Chen, Emmanouil Benetos, Jie Fu, Gus Xia, Roger Dannenberg, Wei Xue, Shiyin Kang и Yike Guo. “ChatMusician: Understanding and Generating Music Intrinsically with LLMs”. B: *Findings of the Association for Computational Linguistics: ACL 2024*. 2024, с. 6252—6271. URL: <https://aclanthology.org/2024.findings-acl.373/>.
- [22] Yixiao Zhang, Ziyu Wang, Dingsu Wang и Gus Xia. “BUTTER: A Representation Learning Framework for Bi-directional Music-Sentence Retrieval and Generation”. B: *Proceedings of the 1st Workshop on NLP for Music and Audio*. 2020, с. 54—58. URL: <https://aclanthology.org/2020.nlp4musa-1.11/>.