



НИУ ВШЭ, Факультет
компьютерных наук
ОП “Искусственный интеллект”

Научный руководитель:
к.ф.-м.н., доцент
Е. О. Кантонистова
Соруководитель: П. М. Гринберг

Москва, 2026

Улучшение генерации музыки с помощью обучения с подкреплением

Исследовательский проект

Александр Александрович Вальсамакин
Даниил Григорьевич Удалов




Какие модели можно использовать?






Введение: генерация музыки по тексту



Одна музыкальная идея может быть представлена как текстовая запись, *MIDI*-файл или готовый звук. В работе нас интересует именно *MIDI*.



Введение: Сложность задачи




- Цельность музыки задаётся не одним токеном, а всей последовательностью.
- Важны форма, ритм, гармония, инструменты и соответствие текстовому запросу.
- При обучении “предсказывать следующий токен” часть общего музыкального сигнала теряется.

Цель работы

Оценивать уже сгенерированный *MIDI*-фрагмент и использовать этот сигнал для дообучения модели методами обучения с подкреплением.



Введение: Схема дообучения модели



- *Text2midi* по текстовому запросу порождает несколько кандидатов *MIDI*.
- Модель может оценивать кандидаты, например, по правилам и с помощью нейросетевого оценщика.
- Для дообучения по внешней оценке можно рассматривать *DPO*, *PPO* и *GRPO*.



Обзор литературы: внешняя оценка качества

- В ряде работ музыкальный результат оценивается не по токенам, а по внешнему сигналу качества.
- *RL-Duet* использует награду за согласованность с партией второго исполнителя.
- *MusicRL* опирается на попарные сравнения и внешний оценщик музыкального качества.
- Работа Kumar et al. показывает: чтобы дообучение работало, сигнал оценки должен быть достаточно информативным.
- *Text2midi-InferAlign* применяет награду при выборе кандидатов; в нашей работе похожий сигнал переносится в дообучение.

Источники: RL-Duet: Jiang et al., 2020; MusicRL: Cideron et al., 2024; Kumar et al., 2026; Text2midi-InferAlign: Roy et al., 2025.



Распределение работы

Александр Александрович Вальсамакин

- Выбор и подготовка данных для графового критика.
- Обучение и анализ нейросетевого оценщика.
- Эксперименты с графовым представлением музыкальных данных.

Даниил Григорьевич Удалов

- GRPO-дообучение *Text2midi*-модели.
- Формализация правил и расчёт наград.
- Внедрение критика в схему RL-дообучения.



Всего песен: 26 178

Количество
уникальных
исполнителей: 6 207


Всего нот: 1 338 346

Всего аккордов: 449
072

“Hey Jude” by The Beatles



Full song



HookTheory.com



Каждый клип — JSON-объект типа:

- meta: split, key, tempo, meter
- [melody]: beat, duration, scale, degree, octave, rest flag
- [chords]: beat, duration, root, type, inversion, applied, adds, omits, alterations, suspensions, borrowed, rest flag

Cmaj7add9

Asus4

D7/V

root type adds suspensions
applied



GNN Critic

Графовое представление данных





Схема иерархии и типов связей



Иерархия в формате нотной записи



GNN Critic

Пример искажений треков



Нотная запись до и после искажений



GNN Critic

Схема обучения графового критика

$\mathcal{G}$ – исходный граф

$\tilde{\mathcal{G}}$ – искаженный граф

Модель обучается
выполнять условие:

$$s_{\theta}(\mathcal{G}) > s_{\theta}(\tilde{\mathcal{G}})$$




Схема обучения графового критика



GNN Critic

Схема применения графового критика




Схема применения графового критика



GNN Critic

Схема обучения графового учителя

$\mathcal{G}$ – исходный граф

$\tilde{\mathcal{G}}$ – искаженный граф

Модель обучается
выполнять условие:

$$s_{\theta}(\mathcal{G}) > s_{\theta}(\tilde{\mathcal{G}})$$





Схема обучения графового ~~критика~~ учителя



GNN Critic

Схема обучения графового ученика



Общая схема обучения графового ученика



Ноты на входе: C – E – G – B

Возможная интерпретация	Функция	Лад / тональный контекст
Cmaj7	I — тоника	C Ionian
Em(b13)	i — модальная тоника	E Phrygian
G6sus4 (или G(add4,6))	I с суспензией / тоническое зависание	G Ionian
Cmaj7	III — медиантовая окраска	A melodic minor
B $\emptyset$ (addb9) (условная неполная трактовка)	i $\emptyset$ — локрийская тоника	B Locrian
Cmaj7	V — доминантовая ступень без классического доминантового напряжения	F Lydian



Аккордовый оценщик выбирает кандидата с наибольшим количеством очков соответствия, которые считаются как:

$$q(c, P_w) = q_+(c, P_w) - q_-(c, P_w),$$

- P_w — наблюдаемые ноты;
- c — аккордовый кандидат;
- q_+ — **положительный вклад** объяснённых признаков;
- q_- — **штрафы за несоответствия**.



Сравнение случайных и теоретически обоснованных искажений

<i>Corruption family</i>	<i>Pooling</i>	<i>Best rank acc</i> ↑
<i>Theory-aware</i>	<i>mean_max</i>	1.0000
<i>Graph</i>	<i>mean_max</i>	0.8750



Проверка обобщения teacher-модели на OOD-corruptions

<i>Group</i>		<i>Mean gap</i>	<i>Global RankAcc</i>	<i>Interpretation</i>
<i>Harmful corruptions</i>	<i>OOD</i>	0.6649	0.5504	Новые вредные искажения в среднем понижают <i>score</i>
<i>Benign transformations</i>		0.0110	0.5012	Безвредные преобразования почти не создают систематический штраф



Staged training

<i>Training mode</i>	<i>Best IntraAcc</i> ↑	<i>Best InterAcc</i> ↑	<i>BinaryAcc</i> ↑
<i>MLM → corruption</i>	0.9118	0.8994	0.7486
<i>Corruption from scratch</i>	0.9007	0.8962	0.7489

- *BinaryAcc* — точность бинарного различения исходных и искажённых графов.
- *IntraAcc* — точность упорядоченных пар *clean/corrupted* в рамках одного трека.
- *InterAcc* — точность упорядоченных пар *clean/corrupted* с разными треками.



Feature ablation: dynamic weighting, HGT и learned logit fusion

<i>Variant</i>	<i>Backbone</i>	<i>Dynamic weights</i>	<i>Logit fusion</i>	<i>Best IntraAcc</i> ↑	<i>Best InterAcc</i> ↑	<i>BinaryAcc</i> ↑
<i>Baseline</i>	<i>SAGE</i>	<i>no</i>	<i>no</i>	0.8547	0.8472	0.7668
<i>HGT</i>	<i>HGT</i>	<i>no</i>	<i>no</i>	0.8410	0.8409	0.7537
<i>Dynamic weights</i>	<i>SAGE</i>	<i>yes</i>	<i>no</i>	0.8530	0.8494	0.7731
<i>Learned logit fusion</i>	<i>SAGE</i>	<i>no</i>	<i>yes</i>	0.8408	0.8523	0.7761

- *BinaryAcc* — точность бинарного различения исходных и искажённых графов.
- *IntraAcc* — точность упорядоченных пар *clean/corrupted* в рамках одного трека.
- *InterAcc* — точность упорядоченных пар *clean/corrupted* с разными треками.

Источники: *AnalysisGNN: Unified Music Analysis with Graph Neural Networks*: Karystinaios et al., 2025.



Финальная *teacher*-конфигурация

<i>Backbone</i>	<i>Dynamic weights</i>	<i>Logit fusion</i>	<i>Hidden / layers</i>	<i>Pooling</i>	<i>Local context</i>	<i>MLM / corr epochs</i>	<i>Best IntraAcc</i> ↑	<i>Best InterAcc</i> ↑	<i>BinaryAcc</i> ↑
SAGE	yes	yes	256 / 4	<i>mean_max</i>	<i>attention</i>	30 / 39	0.9275	0.9250	0.8456

- *BinaryAcc* — точность бинарного различения исходных и искажённых графов.
- *IntraAcc* — точность упорядоченных пар *clean/corrupted* в рамках одного трека.
- *InterAcc* — точность упорядоченных пар *clean/corrupted* с разными треками.



Сравнение ручного и обучаемого *scoring* для восстановления аккордов из *MIDI*

<i>Scoring</i>	<i>Top-1 exact</i> ↑	<i>Top-5 contains GT</i> ↑	<i>Root acc</i> ↑	<i>Type acc</i> ↑	<i>Root+Type acc</i> ↑	<i>Mode acc</i> ↑	<i>Inversion acc</i> ↑
<i>Learned weights</i>	0.9216	0.9907	0.9753	0.9864	0.9690	0.9324	0.9811
<i>Manual</i>	0.7641	0.9184	0.9249	0.8368	0.8147	0.9061	0.9213



Качество восстановления аккордов по типам

<i>Type</i>	<i>Manual weights</i> ↑	<i>Learned weights</i> ↑
<i>triad / 5</i>	0.915	0.938
<i>seventh / 7</i>	0.227	0.867
<i>ninth / 9</i>	0.000	0.850
<i>eleventh / 11</i>	0.000	0.886
<i>thirteenth / 13</i>	0.000	0.089



$$\mathcal{L} = \lambda_s \mathcal{L}_{score} + \lambda_r \mathcal{L}_{rank} + \lambda_m \mathcal{L}_{margin} + \lambda_g \mathcal{L}_{graph} + \lambda_t \mathcal{L}_{type} + \lambda_l \mathcal{L}_{local}.$$

$$\mathcal{L}_{graph} = \left\| P_g z_G^S - z_G^T \right\|_2^2$$

$$\mathcal{L}_{type} = \sum_{\tau} \left\| P_{\tau} z_{\tau}^S - z_{\tau}^T \right\|_2^2$$

$$\mathcal{L}_{local} = \left\| P_l u^S - u^T \right\|_2^2$$

z_G^S и z_G^T — графовые *embeddings student-* и *teacher-*моделей.

z_{τ}^S и z_{τ}^T — *pooled*-представления по типам вершин.

u^S и u^T — локальные *summary*-признаки.

Матрицы P_g , P_{τ} , P_l являются *projection adapters*, позволяющими сопоставить пространства *student* и *teacher*.



Влияние дистилляции промежуточных представлений *teacher*-модели

<i>Variant</i>	<i>Batch rank acc</i> ↑	<i>Spearman</i> ↑	<i>Pearson</i> ↑	<i>MAE</i> ↓	<i>Score distill loss</i> ↓
<i>Intermediate</i>	0.6787	0.4173	0.3588	2.3121	3.7560
<i>No intermediate</i>	0.6111	0.2712	0.1728	2.5432	4.2046

Batch rank acc — доля корректных сравнений между всеми положительными и отрицательными примерами внутри батча.

Spearman — ранговая корреляция между оценками *student* и *teacher*.

Pearson — линейная корреляция между этими оценками.




Финальное сравнение *observer*-конфигураций

<i>Observer variant</i>	<i>Intermediate losses</i>	<i>Pair rank acc</i> ↑	<i>Batch rank acc</i> ↑	<i>Spearman</i> ↑	<i>Pearson</i> ↑	<i>MAE</i> ↓
<i>Intermediate</i>	<i>yes</i>	0.8692	0.8464	0.6926	0.6873	2.0698
<i>No intermediate</i>	<i>no</i>	0.8509	0.8387	0.7135	0.6832	1.4717



Постановка задачи генерации MIDI по тексту



Этап	Операция	Зачем нужна
1	Выбор запроса	Фиксирует текстовое условие для группы кандидатов.
2	Генерация	Модель порождает несколько MIDI-вариантов.
3	Декодирование	Токены переводятся в MIDI-представление.
4	Награда	Правила или критик оценивают готовый фрагмент.
5	Нормировка	Кандидаты сравниваются внутри одной группы.
6	Обновление	GRPO усиливает варианты лучше среднего.



GRPO: преимущество и функция потерь

- Кандидаты сравниваются только внутри одной группы ответов на запрос.
- Если награда выше среднего, кандидат усиливается; если ниже — ослабляется.

$$\bar{r} = \frac{1}{G} \sum_{j=1}^G r_j, \quad \hat{A}_i = \frac{r_i - \bar{r}}{s_r + \varepsilon_A}.$$


$$\rho_{i,t}(\theta) = \frac{\pi_{\theta}(o_{i,t} \mid \mathbf{q}, o_{i,<t})}{\pi_{\theta_{\text{old}}}(o_{i,t} \mid \mathbf{q}, o_{i,<t})}.$$

$$\mathcal{L}_{\text{GRPO}} \sim -\min \left(\rho_{i,t} \hat{A}_i, \rho_{i,t}^{\text{orp}} \hat{A}_i \right) + \beta D_{i,t}.$$

- Отсечение ограничивает слишком резкое обновление, а KL удерживает модель рядом с исходной.
- Отдельная модель ценности не требуется.



Награды: компоненты на основе правил



- Правила проверяют, насколько готовый *MIDI*-фрагмент согласован с запросом и не содержит грубых артефактов.



Награды: формализация правил

Мягкие ограничения

$$T(z; l, c, h) = \begin{cases} 0, & z \leq l \text{ или } z \geq h, \\ \frac{z-l}{c-l}, & l < z < c, \\ 1, & z = c, \\ \frac{h-z}{h-c}, & c < z < h. \end{cases}$$

Примеры компонент


$$R_{\text{dur}} = T(D; 8, 64, 160)$$

$$R_{\text{dens}} = T\left(\frac{|N|}{\max(D, 1)}; l, c, h\right)$$

- Мягкие функции чаще различают кандидатов внутри группы.
- Умеренная плотность снижает риск перегруженных фрагментов.



Награды: сигнал критика



- Критик добавляет более общий сигнал качества, когда одних правил недостаточно.



Итоговая функция награды

Базовая схема

$$R(q, o_i) = \sum_k \lambda_k R_k(q, o_i)$$

- сумма активных компонент на основе правил;
- веса λ_k задают важность признаков;
- невалидные MIDI получают штраф.

С критиком

$$R(q, o_i) = \sum_k \lambda_k R_k(q, o_i) + \lambda_c R_{\text{критик}}(q, o_i)$$


- критик добавляет более общий сигнал качества;
- смешанная схема стабилизирует шумный сигнал критика.



Модель Text2midi

- *Text2midi* — языковая модель для генерации *MIDI* по текстовому описанию.
- Она работает в событийном представлении музыки и авторегрессионно порождает музыкальные токены.
- В работе используется как базовый генератор, который затем дообучается методом **GRPO**.

Источник: amaai-lab/text2midi.





Настройка параметров модели

- Полное дообучение с подкреплением всех весов дорого и рискованно.
- Основной режим — LoRA при замороженной базовой модели.
- Проверялись слои внимания, полносвязные блоки и комбинированная настройка.
- Наиболее устойчивым режимом стал LoRA на полносвязных блоках декодера.




Семейства конфигураций

Семейство	Что проверяется
Правила	Тональность, метр, длительность, плотность, доля ударных.
Критик	Достаточен ли обобщённый сигнал качества.
Правила + критик	Стабилизирует ли этап с правилами шумный сигнал критика.
Учебный режим	Помогает ли постепенное усложнение запросов.
LoRA / частичное обучение	Можно ли менять модель без разрушения генератора.




Результаты: обучение по правилам



На узком наборе запросов модель реагирует на сигнал правил: отдельные компоненты награды начинают меняться в ожидаемом направлении.




Результаты: учебная последовательность



Вертикальные границы соответствуют этапам, где постепенно менялись тональность, метрическая структура и стиль.




Результаты: критик после правил



Предварительное обучение на правилах стабилизирует подключение более шумного сигнала критика.




Результаты: широкий набор запросов



Широкое распределение текстовых запросов делает динамику награды менее устойчивой и хуже интерпретируемой.



А/Б-сравнение с базовой моделью



Попарный А/В-тест проводится между базовой и дообученной моделью по той награде, по которой выполнялось дообучение.



- MIDI переводились в ABC-нотацию и оценивались внешней языковой моделью.
- Сравнивались базовая модель и схема “правила затем критик”.

Модель	Средняя	Медиана	Макс.
Базовая модель	1.90	2.00	6.00
После правил и критика	2.80	2.00	9.00



Анализ ошибок и ограничений

- Плотность нот легко переоптимизировать.
- Базовая модель иногда создаёт пустые или преимущественно ударные дорожки.
- Сигнал критика шумнее правил и требует стабилизации.
- Запросы лучше усложнять постепенно, иначе сигнал становится слишком неоднородным.



- Реализован полный цикл GRPO-дообучения *Text2midi*.
- Награды на основе правил дают интерпретируемый диагностический сигнал.
- Сигнал критика полезен, но требует стабилизации.
- Главные ограничения: шум награды, запросы и переоптимизация отдельных признаков, слабость базовой модели




Appendix

Распределения тональностей и ладов



Распределение тональностей




Распределение ладов



Appendix

Распределения ступеней и типов аккордов



Распределение ступеней аккордов



Распределение типов аккордов



Appendix

Обучение графового учителя

Признаки каждой вершины проецируются в общее скрытое пространство:

$$h_v^{(0)} = \phi_{\tau_v}(x_v),$$

где ϕ_{τ_v} — *encoder* для типа вершины τ_v , реализованный как *MLP*.

Для каждого типа ребра r сообщения вычисляются отдельно:

$$m_{u \rightarrow v}^{(l,r)} = W_r^{(l)} h_u^{(l)}.$$

Сообщения от соседей агрегируются:

$$m_v^{(l)} = \sum_{r \in R} \text{AGG}_{u \in N_r(v)} m_{u \rightarrow v}^{(l,r)}.$$

Состояние вершины обновляется с *residual*-связью, нормализацией и нелинейностью:

$$h_v^{(l+1)} = \text{ReLU}\left(\text{LN}\left(h_v^{(l)} + m_v^{(l)}\right)\right).$$

После нескольких *GNN*-слоёв модель получает контекстуализированные представления узлов. Затем выполняется *pooling* по типам вершин:

$$g_t = \frac{1}{|V_t|} \sum_{v \in V_t} h_v^{(L)},$$

где V_t — множество вершин типа t .

После объединения векторов разных типов получается общий *embedding* графа:

$$g = \psi(g_1 \| g_2 \| \dots \| g_T),$$

где $\|$ — конкатенация, а ψ — линейная проекция или *MLP*. Итоговая оценка графа:

$$s_\theta(\mathcal{G}) = f_{\text{score}}(g).$$

Для обучения используется *contrastive ranking loss*:

$$\mathcal{L}_{\text{rank}} = \text{softplus}\left(-\left(s_\theta(\mathcal{G}) - s_\theta(\tilde{\mathcal{G}}) - m\right)\right),$$

где m — *margin*. Функция штрафует модель, если *score* искажённого графа слишком близок к *score* исходного или превосходит его.

Дополнительно может использоваться бинарная классификационная компонента:

$$\mathcal{L}_{\text{bin}} = \frac{1}{2} \left(\text{BCE}(s_\theta(\mathcal{G}), 1) + \text{BCE}(s_\theta(\tilde{\mathcal{G}}), 0) \right).$$

Общая функция потерь учителя:

$$\mathcal{L}_{\text{teacher}} = \lambda_{\text{rank}} \mathcal{L}_{\text{rank}} + \lambda_{\text{bin}} \mathcal{L}_{\text{bin}} + \lambda_{\text{local}} \mathcal{L}_{\text{local}} + \lambda_{\text{rec}} \mathcal{L}_{\text{rec}}.$$



Appendix

Обучение графового ученика

После построения *MIDI*-графа ученик использует компактную гетерогенную *GNN*. Для каждой вершины строится начальное представление:

$$z_v^{(0)} = \phi_{\tau_v}(x_v),$$

после чего несколько графовых слоёв обновляют его через сообщения от соседей:

$$z_v^{(l+1)} = \sigma \left(\text{LN} \left(z_v^{(l)} + \sum_r \text{AGG}_{u \in N_r(v)} W_r^{(l)} z_u^{(l)} \right) \right).$$

Далее применяется *pooling* по вершинам и строится *embedding* *MIDI*-графа:

$$z_G = \text{Pool} \left(\{z_v^{(L)}\}_{v \in V_M} \right).$$

Итоговая оценка ученика равна:

$$s_\varphi(\mathcal{G}_M) = f_{\text{student}}(z_G).$$

Ученик обучается не на ручных метках, а на оценках учителя. Если учитель присваивает музыкальному фрагменту *score* $s_\theta(\mathcal{G})$, то ученик минимизирует ошибку дистилляции:

$$\mathcal{L}_{\text{distill}} = |s_\varphi(\mathcal{G}_M) - s_\theta(\mathcal{G})|,$$

или её сглаженный вариант:

$$\mathcal{L}_{\text{distill}} = \text{SmoothL1}(s_\varphi(\mathcal{G}_M), s_\theta(\mathcal{G})).$$

Для пар *clean/corrupted* дополнительно используется *ranking loss*:

$$\mathcal{L}_{\text{student-rank}} = \text{softplus} \left(- \left(s_\varphi(\mathcal{G}_M) - s_\varphi(\tilde{\mathcal{G}}_M) \right) \right).$$



Appendix

Положительная часть аккордового score

Компоненты положительной части аккордового score

<i>Компонента</i>	<i>Интерпретация</i>
<code>mode_match(c)</code>	Совпадение лада
<code>bass_match(c)</code>	Совпадение басовой ноты
$ P_w \cap B(c) $	Количество совпадающих нот
<code>explained_extras(c, P_w)</code>	Надстройки



Компоненты штрафной части аккордового score

<i>Компонента</i>	<i>Интерпретация</i>
$\text{Unexplained}(c, P_w)$	Ноты которые не объясняются кандидатом
$\text{MissingCore}(c, P_w)$	Ноты кандидата которых нет в MIDI
$\text{borrowed_mode_penalty}(c)$	Штраф за заимствованный лад
$\text{mode_distance}(c)$	Штраф за расстояние до заимствованного лада
$\text{body_size_penalty}(c)$	Штраф за размер аккорда
$\text{complexity_penalty}(c)$	Штрафы за добавленные ступени, задержания, альтерации и пропущенные обязательные тона.



Appendix

Пример применения аккордового оценщика

Пусть в момент времени t наблюдаются *MIDI*-ноты $C - E - G - B\flat$, тогда $P_t = \{C, E, G, B\flat\}$.

Кандидат	Тело аккорда	Совпадения и штрафы	Итог
$C7$	$B(C7) = \{C, E, G, B\flat\}$	$P_t \cap B(C7) = \{C, E, G, B\flat\};$ MissingCore = $\emptyset$; Unexplained = $\emptyset$	Высокий score: полный доминантсепт-аккорд.
C major	$B(C) = \{C, E, G\}$	Трезвучие объясняется, но $B\flat$ остаётся необъяснённым: Unexplained = $\{B\flat\}$	Score ниже, если $B\flat$ не считается допустимой добавленной или альтерированной степенью.
$Am7\flat5 / C$	$B(Am7\flat5) = \{A, C, E\flat, G\}$	Есть C и G , но отсутствуют A и $E\flat$; вместо $E\flat$ наблюдается E : MissingCore = $\{A, E\flat\}$	Совпадение баса C не компенсирует штрафы: score ниже, чем у $C7$.